ÉCOLE NATIONALE D'INGÉNIEURS DE TUNIS

Département Génie Industriel

Rapport de mini projet de traitement numérique des signaux

Elaboré par :

Bejaoui Saad Eddine

Asmi Mohamed Amine

Encadré par :

Mme. MEHERZI Soumaya

1ère Année MIndS

Année universitaire : 2024/2025

Table des matières

Table des figures **1**

1 Introduction **2**

2 Réalisation **3**
2.1 Banc de filtres d'analyse 3
2.2 Décimation 9
2.3 Quantification / Codage 11
2.4 Interpolation 13
2.5 Filtres de synthèse 14

3 Conclusion **20**

Références **21**

Table des figures

1 Représentations temporelle et spectrale du signal original. 3
2 Réponse fréquentielle du filtre passe bas Retwin d'ordre 7 en gain et en phase. 4
3 Comparaison entre les réponses fréquentielles des filtres passe bas Hamming d'ordre 7 (Rouge) et Rectwin d'ordre 7 (Bleu) 4
4 Comparaison entre les réponses fréquentielles des filtres passe bas Hamming d'ordre 24 (Rouge), Hamming d'ordre 7 (Bleu) et Rectwin d'ordre 7 (Noir) 5
5 Représentation du contenu spectral de la bande BF du signal s après filtrage. 6
6 Réponse fréquentielle du filtre passe haut Hamming d'ordre 24 en gain et en phase. 7
7 Représentation du contenu spectral de la bande HF du signal s après filtrage. 7
8 Comparaison temporelle entre le signal original (Bleu) et le signal reconstitué (Rouge) 8
9 Comparaison entre les réponses fréquentielles des filtres passe bas RIF Hamming d'ordre 24 (Rouge) et RII Butterworth d'ordre 4 (Bleu). 9

10 Spectres de s_{1d} et s_{2d}. 10
11 Courbes du RSB obtenu en fonction du nombre de bits pour s_{1d} et s_{2d} 12
12 Représentation du contenu spectral de $sq1_{\text{up}}$ et $sq2_{\text{up}}$ après interpolation. 13
13 Spectres de y_1 et y_2, les sorties des filtres. 14

Remerciements

Nous tenons à exprimer notre profonde gratitude à notre encadrante et professeure de travaux pratiques Mme. MEHERZI Soumaya pour son accompagnement, sa disponibilité et la qualité de ses explications tout au long de ce mini-projet. Son expertise et ses conseils nous ont permis de mieux comprendre les concepts du traitement du signal et de mener à bien ce travail dans des conditions optimales.

1 Introduction

Le codage en sous-bandes est une technique de traitement du signal qui consiste à décomposer un signal en plusieurs composantes fréquentielles, généralement à l'aide d'un banc de filtres. Chaque sous-bande peut ensuite être traitée indépendamment (par exemple, quantifiée avec une précision adaptée à son importance perceptuelle), puis recombinée à la réception. Ce principe est à la base de nombreux systèmes de compression dans le domaine audio (Codec MP3), image (JPEG2000) ou encore dans les télécommunications. Il permet de réduire efficacement le débit de transmission tout en préservant la qualité perçue du signal.
Le but de ce projet est de concevoir, implémenter et évaluer une chaîne complète de compression/décompression audio basée sur le codage en sous-bandes, à l'aide de l'environnement Octave/Matlab.
Comment comprimer un signal vocal de manière efficace, c'est-à-dire en réduisant son débit binaire tout en conservant une qualité d'écoute acceptable ? Cela soulève plusieurs défis : choisir une architecture de codage adaptée, garantir une bonne séparation fréquentielle et allouer judicieusement les ressources(nombre de bits par bande).
La chaîne de traitement adoptée dans ce projet suit une architecture en 5 grandes étapes :

1. **Banc de filtres d'analyse** : séparation du signal en deux sous-bandes (basses et hautes fréquences).
2. **Décimation** : réduction du nombre d'échantillons dans chaque bande.
3. **Quantification** : codage numérique des échantillons, avec allocation différente de bits entre bandes.
4. **Interpolation** : restauration de la fréquence d'échantillonnage d'origine.
5. **Filtres de synthèse** : recombinaison des deux bandes en un signal reconstruit.

L'évaluation de la performance de la chaîne de traitement est conduite selon deux approches complémentaires. D'une part, une évaluation objective repose sur le calcul du RSB (Rapport Signal sur Bruit) et du débit binaire total, permettant de mesurer quantitativement la fidélité de la restitution ainsi que l'efficacité de la compression, nous avons également opté pour le score STOI pour estimer l'intelligibilité de la parole. D'autre part, une évaluation subjective est réalisée par des tests d'écoute comparant le signal original et le signal reconstruit, afin de juger de la qualité perçue. Cette double approche garantit une validation complète, à la fois technique et perceptuelle, du système mis en œuvre. Cette double approche nous permet de valider non seulement la précision numérique de notre traitement, mais aussi sa pertinence perceptuelle dans le cadre d'un codage vocal.

2 Réalisation

2.1 Banc de filtres d'analyse

Etape 1 : Lecture du signal et stockage dans `s` et `Fe`.
Le signal vocal a été lu à l'aide de la fonction `audioread`, ce qui nous a permis d'obtenir la forme temporelle du signal ainsi que sa représentation fréquentielle. Ces visualisations nous donnent un premier aperçu de la densité spectrale et de la durée du signal étudié.

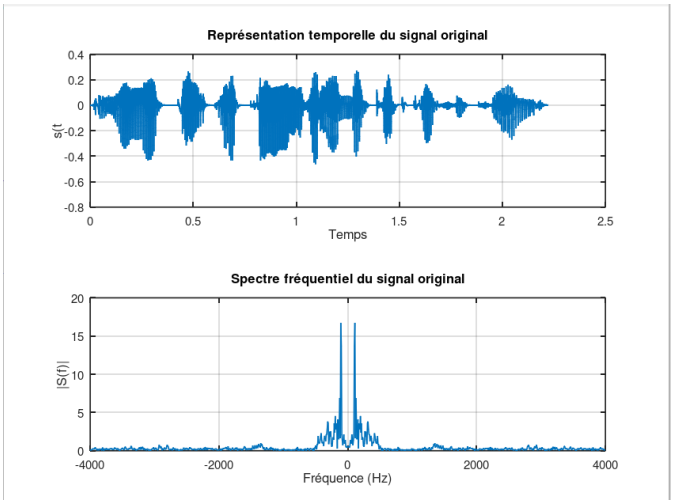

FIGURE 1 – Représentations temporelle et spectrale du signal original.

Etape 2 : Récupération de la bande BF du signal.

- Conception d'un filtre passe-bas de type rectangulaire d'ordre 7 avec fréquence de coupure $f_c = F_e/4$. Sa réponse fréquentielle présente une bande passante large mais une forte ondulation (lobes secondaires élevés), ce qui dégrade la qualité du filtrage.

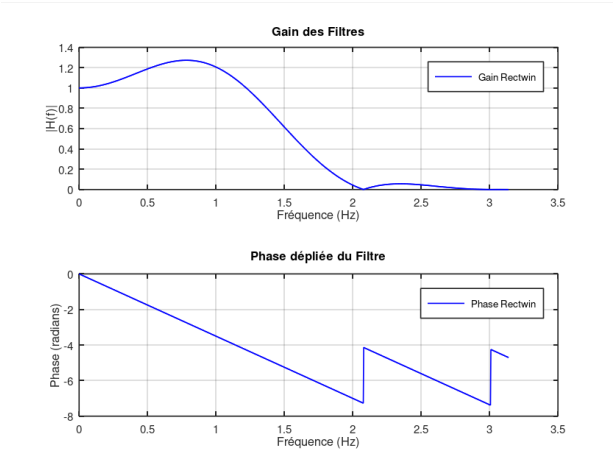

FIGURE 2 – Réponse fréquentielle du filtre passe bas Retwin d'ordre 7 en gain et en phase.

- Conception d'un filtre passe-bas de type Hamming (ordre 7). La fenêtre de Hamming réduit considérablement les lobes secondaires, au prix d'une bande de transition un peu plus large.

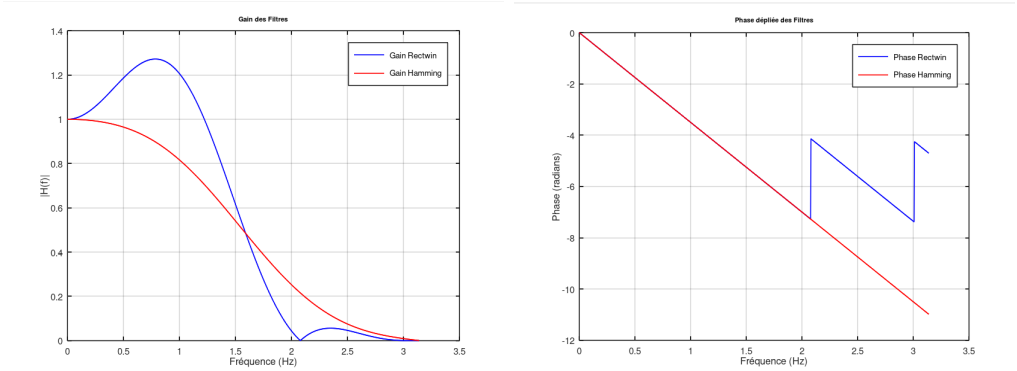

FIGURE 3 – Comparaison entre les réponses fréquentielles des filtres passe bas Hamming d'ordre 7 (Rouge) et Rectwin d'ordre 7 (Bleu)

Comparée à la fenêtre rectangulaire d'ordre 7, la fenêtre de Hamming de même ordre présente des performances nettement supérieures en termes de filtrage fréquentiel. En effet, bien que les deux fenêtres possèdent une largeur de lobe principal similaire (déterminant la bande de transition), la fenêtre de Hamming réduit significativement l'amplitude des lobes secondaires. Cette atténuation plus marquée des lobes secondaires limite les oscillations indésirables dans la bande atténuée, ce qui diminue le risque de repliement spectral et améliore la sélectivité du filtre.

À l'inverse, la fenêtre rectangulaire engendre des lobes secondaires très élevés, traduisant une forte diffusion de l'énergie spectrale hors de la bande utile. Ainsi, le filtre basé sur la fenêtre de Hamming est bien mieux adapté à un découpage propre du spectre, malgré une bande de transition légèrement plus large.

- Conception d'un filtre Hamming d'ordre 24 avec la même fréquence de coupure.

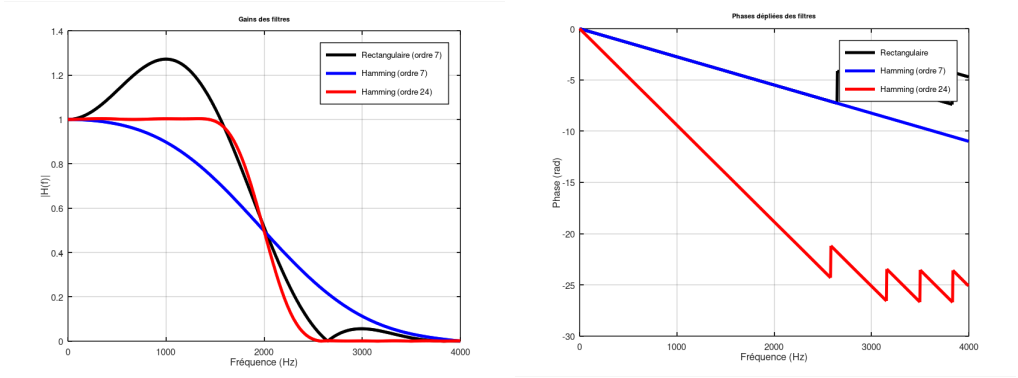

FIGURE 4 – Comparaison entre les réponses fréquentielles des filtres passe bas Hamming d'ordre 24 (Rouge), Hamming d'ordre 7 (Bleu) et Rectwin d'ordre 7 (Noir)

L'ajout du filtre Hamming d'ordre 24 permet d'améliorer considérablement les performances du filtrage fréquentiel. Par rapport aux filtres de même fréquence de coupure mais d'ordre plus faible (rectangulaire 7 et Hamming 7), le Hamming 24 présente une bande de transition nettement plus étroite, ce qui permet une séparation plus franche entre la bande passante et la bande atténuée. De plus, l'atténuation des lobes secondaires y est largement renforcée, limitant encore davantage le repliement spectral. Bien que les trois filtres présentent une phase globalement linéaire (propriété typique des RIF symétriques), le filtre Hamming 24 assure une meilleure conservation de la forme d'onde, particulièrement importante pour la qualité du signal vocal reconstruit. Ainsi, l'augmentation de l'ordre du filtre, tout en conservant une fenêtre de Hamming, améliore à la fois la sélectivité et la fidélité du filtrage. Les visualisations superposées des réponses fréquentielles illustrent clairement ces différences et justifient le choix du filtre Hamming 24 comme référence pour les étapes suivantes. Un résumé comparatif des trois filtres est présenté ci-dessous.

Filtre (ordre)	Bande de transition	Atténuation hors bande	Linéarité de phase
Rectangulaire (7)	Large	Faible	Bonne
Hamming (7)	Moyenne	Moyenne	Bonne
Hamming (24)	Étroit	Élevée	Excellente

TABLE 1 – Tableau comparatif des caractéristiques de chaque filtre.

- Application du filtre Hamming ordre 24 au signal s pour obtenir s_1, composante de la bande BF.

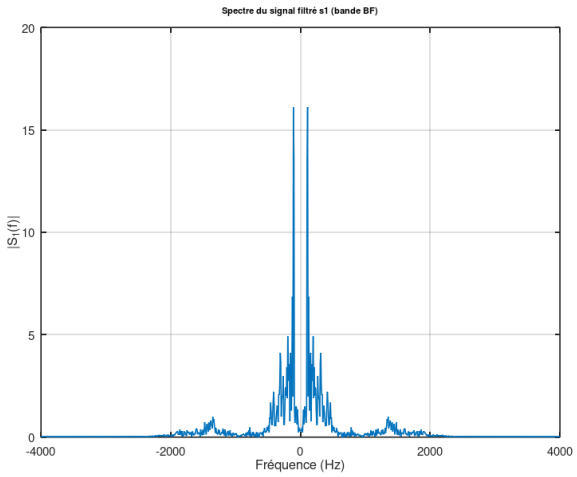

FIGURE 5 – Représentation du contenu spectral de la bande BF du signal s après filtrage.

Le spectre du signal s_1, obtenu après filtrage passe-bas, montre une forte concentration de l'énergie dans la bande de basses fréquences. Comparé au spectre du signal original 1, on observe une nette diminution du contenu spectral au-delà de la fréquence de coupure, ce qui confirme l'efficacité du filtrage réalisé.

Etape 3 : Récupération de la bande HF du signal.

- Conception d'un filtre passe-haut Hamming d'ordre 24 avec fréquence de coupure $f_c = F_e/4$.

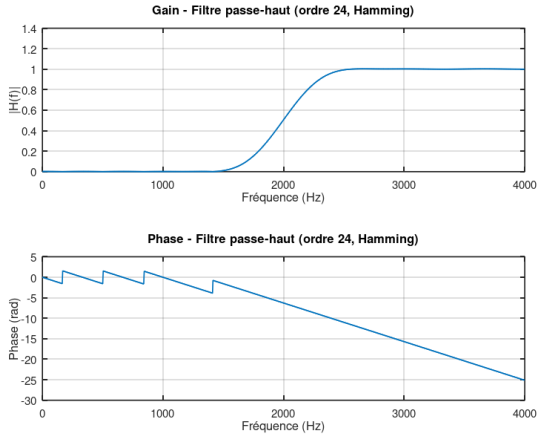

FIGURE 6 – Réponse fréquentielle du filtre passe haut Hamming d'ordre 24 en gain et en phase.

Ce filtre complète la séparation en extrayant les hautes fréquences. L'ordre choisi permet de maintenir une phase linéaire tout en garantissant une séparation nette.

- Application de ce filtre au signal s, ce qui permet d'obtenir le signal s_2, représentant la composante haute fréquence.

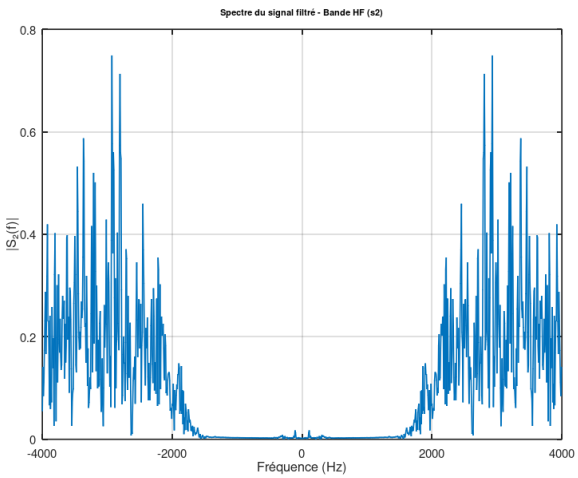

FIGURE 7 – Représentation du contenu spectral de la bande HF du signal s après filtrage.

Le spectre du signal s_2, obtenu après filtrage passe-haut, met en évidence la conservation des composantes haute fréquence du signal. En comparaison avec le

spectre du signal 1, on remarque que les basses fréquences sont fortement atténuées, ce qui reflète une séparation efficace des bandes spectrales.

Etape 4 : Reconstruction du signal $s_r = s_1 + s_2$. L'addition des deux composantes permet une reconstitution fidèle du signal original. L'écoute à l'aide de `soundsc` a confirmé la qualité perceptuelle de la reconstruction.

Etape 5 : Comparaison temporelle entre le signal original et le signal reconstruit.

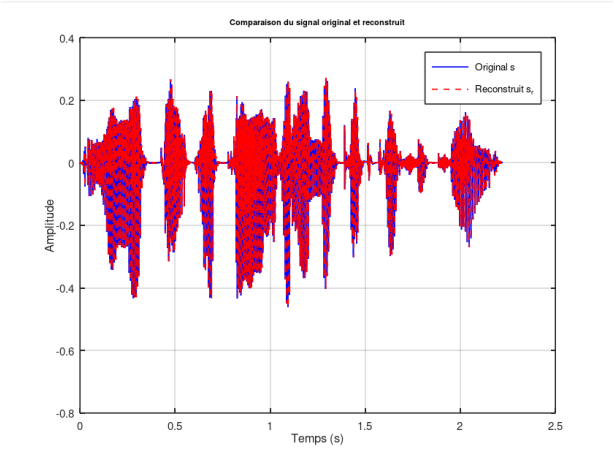

FIGURE 8 – Comparaison temporelle entre le signal original (Bleu) et le signal reconstitué (Rouge)

La superposition des deux courbes montre une excellente similitude, ce qui valide l'efficacité du banc de filtres d'analyse.

Etape 6 : Choix entre RIF et RII.
Nous avons conçu deux filtres RII de type Butterworth et les avons comparés aux filtres FIR Hamming équivalents.

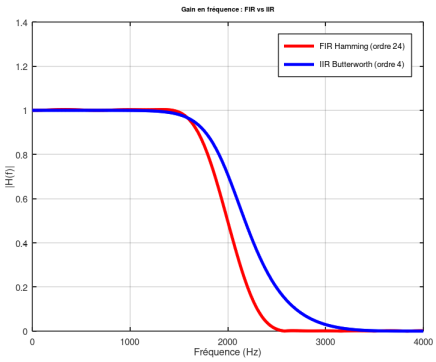

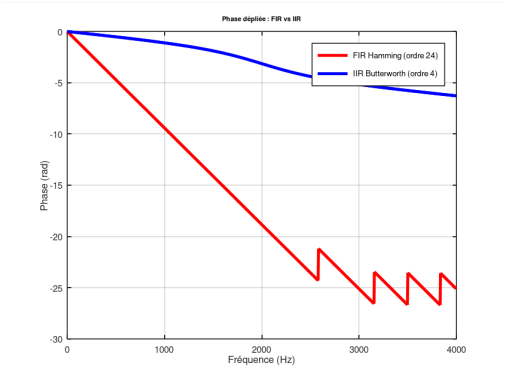

FIGURE 9 – Comparaison entre les réponses fréquentielles des filtres passe bas RIF Hamming d'ordre 24 (Rouge) et RII Butterworth d'ordre 4 (Bleu).

Les figures de comparaison montrent que, si les filtres RIF et RII présentent des gains similaires dans la bande passante, leur comportement en phase est très différent. Le filtre FIR Hamming d'ordre 24 offre une phase strictement linéaire, contrairement au filtre IIR Butterworth d'ordre 4 dont la phase est non linéaire. Ces observations justifient un examen plus détaillé, résumé dans le tableau suivant.

Critère	RIF Hamming	RII Butterworth	Observations
Phase	Linéaire	Non-linéaire	RSB plus faible avec RII
Complexité	Plus élevé	Plus faible	IIR plus compact
Stabilité	Toujours stable	Peut devenir instable	FIR plus sûr
Reconstruction	Excellente	Légèrement décalée	FIR plus fidèle

TABLE 2 – Tableau comparatif des critères des filtres FIR et FII.

Pour garantir une phase linéaire, une stabilité irréprochable et une restitution fidèle, nous avons retenu les filtres FIR de type Hamming dans la suite du traitement.

2.2 Décimation

La décimation est le processus par lequel on réduit la fréquence d'échantillonnage d'un signal. Son but ici est de réduire la quantité de données à transmettre en supprimant des échantillons tout en préservant l'information utile. Le facteur de décimation utilisé est $M = 2$. Cela signifie que l'on conserve un échantillon sur deux. Cette opération ne peut être réalisée qu'après un filtrage adapté, afin d'éviter

l'aliasing. C'est pourquoi les signaux s_1 et s_2 ont d'abord été filtrés dans les étapes précédentes.

Etape 1 : Sous-échantillonnage des signaux s_1 et s_2.
Les deux composantes du signal original (s_1 pour la BF, s_2 pour la HF) ont été sous-échantillonnées séparément à l'aide de la relation :

$$s_{1d} = s_1(1 : M : end)$$

$$s_{2d} = s_2(1 : M : end)$$

Leur fréquence d'échantillonnage devient donc $F_e/2$.

Etape 2 : Visualisation des spectres des signaux décimés s_{1d} et s_{2d}.

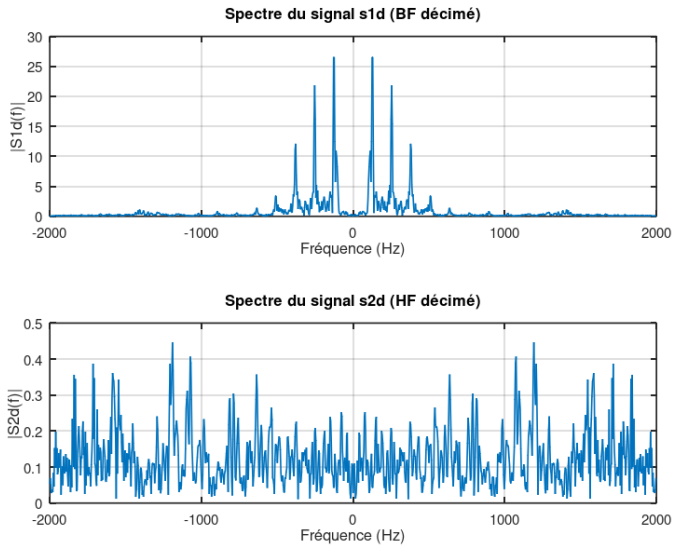

FIGURE 10 – Spectres de s_{1d} et s_{2d}.

Grâce au filtrage préalable (Hamming 24 pour la BF, Hamming 7 pour la HF), le repliement spectral (aliasing) a été évité. Le spectre de s_{1d} montre une bonne conservation de l'énergie dans la bande passante utile. De même, le spectre de s_{2d} montre que la composante haute fréquence a été correctement préservée dans le domaine réduit.

Cette étape permet de diviser par deux la quantité de données, sans perte significative de qualité, et prépare le signal à l'étape de compression suivante (quantification).

2.3 Quantification / Codage

La quantification est une étape clé dans toute chaîne de compression numérique. Elle consiste à approximer un signal analogique ou à valeurs réelles par un ensemble fini de niveaux discrets. Ce processus entraîne une perte d'information (quantification par troncature ou arrondi), mais permet un codage numérique efficace.
Dans notre projet, nous avons appliqué une quantification uniforme, dans laquelle l'intervalle dynamique du signal est découpé en 2^l niveaux (où l est le nombre de bits alloués par échantillon). Les signaux à quantifier sont les deux composantes décimées : s_{1d} (BF) et s_{2d} (HF)

Etape 1 : Présentation de la fonction `unifquant`.
Cette fonction permet de réaliser la quantification uniforme sur un signal x, selon les paramètres : $\begin{cases} \mathrm{A_{min}}, A_{\max} & \text{: amplitude minimale et maximale du signal.} \\ \mathrm{l} & \text{: nombre de bits alloués.} \\ \mathrm{q}= (A_{\max} - A_{\min})/2\mathrm{l}. & \text{: pas de quantification.} \\ \epsilon = x \text{ - } x_q & \text{: erreur de quantification} \end{cases}$
Elle retourne le signal quantifié x_q ainsi qu'une estimation du rapport signal sur bruit de quantification (RSB), calculé analytiquement par :

$$RSB = 10 \cdot \log_{10} \left(\frac{E[x^2]}{E[\epsilon^2]} \right) \tag{2.1}$$

```
function [xq, rsb] = unifquant(x, Amin, Amax, l)
    L = 2^l;
    q = (Amax - Amin) / L;
    xq = round((x - Amin) / q) * q + Amin;
    error = x - xq;
    rsb = 10 * log10(mean(x.^2) / mean(error.^2));
end
```

Listing 1 – Script `Fonction Unifquant`

Etape 2 : Application à s_{1d} et s_{2d}.
Nous avons appliqué la fonction `unifquant` à ces deux signaux pour différentes valeurs de l allant de 2 à 12, par pas de 2 bits.

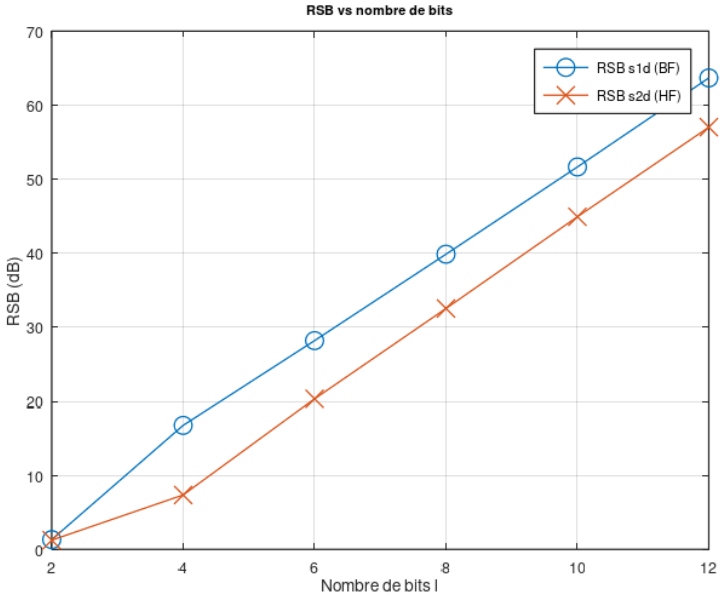

FIGURE 11 – Courbes du RSB obtenu en fonction du nombre de bits pour s_{1d} et s_{2d}

Nombre de bits l	RSB s_{1d} (BF) [dB]	RSB s_{2d} (HF) [dB]
2	1.32	1.24
4	16.74	7.35
6	28.19	20.33
8	39.87	32.54
10	51.64	44.92
12	63.68	57.02

TABLE 3 – Tableau des résultats de RSB pour s_{1d} et s_{2d} en fonction du nombre de bits.

On observe que le RSB croît de façon logarithmique avec le nombre de bits, conformément à la formule. Le signal s_{1d} (BF), contenant les éléments les plus perceptibles de la parole, nécessite davantage de précision (plus de bits) pour éviter une dégradation audible. Le signal s_{2d} (HF), moins sensible à l'oreille, supporte mieux une quantification plus grossière. Ainsi, cette analyse guidera le choix optimal des valeurs de l_1 et l_2 dans la suite du traitement.

2.4 Interpolation

L'interpolation est une opération inverse de la décimation. Elle consiste à rétablir la fréquence d'échantillonnage initiale en insérant des zéros entre les échantillons d'un signal sous-échantillonné. Cette opération est essentielle pour permettre une reconstruction temporelle correcte avant filtrage.
Dans notre cas, les signaux quantifiés sq_1 et sq_2 (issus respectivement de la bande BF et HF) sont interpolés par un facteur $M = 2$, afin de revenir à la fréquence d'échantillonnage d'origine F_e.

Etape 1 : Suréchantillonnage des composantes.
Chaque composante a été interpolée par un simple *upsampling* avec insertion de zéros :

$$sq1_{\text{up}} = \text{upsample}(sq_1, M)$$

$$sq2_{\text{up}} = \text{upsample}(sq_2, M)$$

Ce procédé introduit des spectres mirroirs indésirables qu'il faudra éliminer à l'aide de filtres de synthèse.

Etape 2 : Représentation des spectres après interpolation.

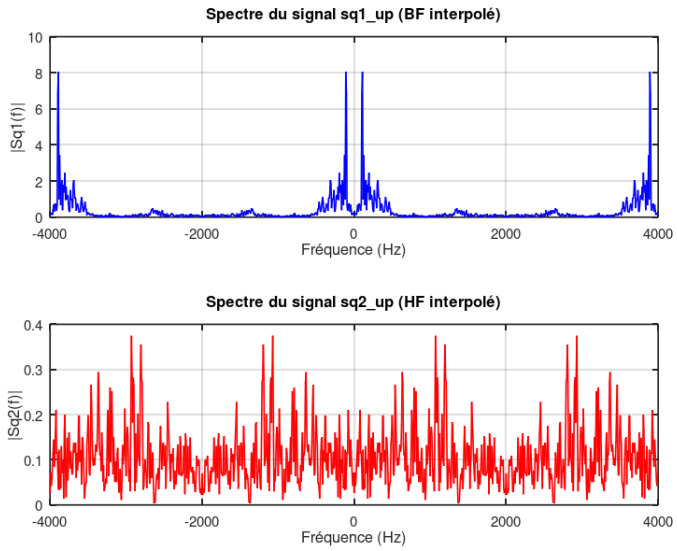

FIGURE 12 – Représentation du contenu spectral de $sq1_{\text{up}}$ et $sq2_{\text{up}}$ après interpolation.

Comme prévu, l'interpolation par $M = 2$ engendre la duplication du spectre original autour de la fréquence $F_e/2$. Ces composantes miroirs sont appelées à être

éliminées lors de l'étape suivante par un filtrage adapté. Ce phénomène est plus visible dans la bande HF, en raison de la concentration spectrale plus étroite du signal quantifié sq_2.

Cette étape prépare donc le signal à sa reconstruction dans le domaine temporel, qui sera réalisée à l'aide des filtres de synthèse dans la prochaine section.

2.5 Filtres de synthèse

La phase de synthèse vise à reconstituer le signal vocal à partir des deux bandes interpolées ($sq1_{\text{up}}$ et $sq2_{\text{up}}$). Cette reconstitution passe par un filtrage adapté pour éliminer les images spectrales introduites lors de l'interpolation.
Les filtres utilisés ici sont les mêmes que ceux utilisés en analyse :

$$\begin{cases} \text{filtre passe-bas Hamming (ordre 24) pour } sq1_{\text{up}} \\ \text{filtre passe-haut Hamming (ordre 24) pour } sq2_{\text{up}} \end{cases}$$

Etape 1 : Application des filtres de synthèse.

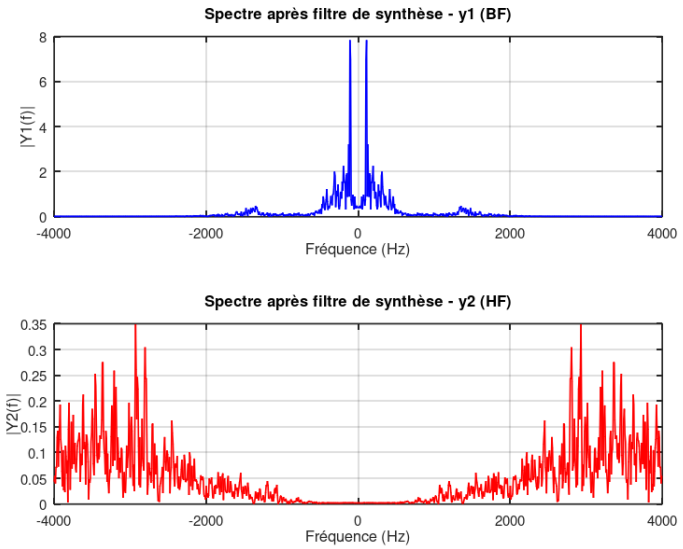

FIGURE 13 – Spectres de y_1 et y_2, les sorties des filtres.

Les spectres des signaux y_1 et y_2 montrent que les filtres de synthèse ont correctement supprimé les composantes spectrales indésirables introduites par l'interpolation. On observe que chaque signal conserve uniquement sa bande fréquentielle utile, respectivement basse pour y_1 et haute pour y_2, confirmant ainsi le

bon fonctionnement du banc de reconstruction. Le signal reconstruit est obtenu par :

$$ss = y_1 + y_2$$

Etape 2 : Décalage temporel résultant.
L'application des filtres RIF (à phase linéaire) en synthèse introduit un retard de groupe proportionnel à leur ordre. Ce retard, exprimé en nombre d'échantillons 2.2. Puis, sachant qu'on a effectué deux passages de filtres (analyse + synthèse) de même ordre (24), on calcule le retard de groupe total 2.3 et on conclut après le retard temporel 2.4.

$$\text{Retard (en échantillon)} = \frac{N}{2} \tag{2.2}$$

$$\tau_{\text{échantillon}} = \frac{N}{2} + \frac{N}{2} = N \tag{2.3}$$

$$\tau_{\text{secondes}} = \frac{N}{F_e} \tag{2.4}$$

N : ordre du filtre
F_e : fréquence d'échantillonnage

Ce décalage est systématiquement pris en compte en phase de comparaison pour aligner temporellement le signal s original et ss synthétisé. Il est essentiel d'aligner correctement ces deux signaux afin de garantir un calcul fidèle du RSB. Ce décalage peut aussi être interprété comme un bit de retard si l'on exprime l'information codée en fonction de la quantification binaire appliquée aux sous-bandes.
En effet, Le débit binaire de la chaîne est calculé en tenant compte de la décimation des sous-bandes à $F_e/2$, exprimé en [bits/seconde] et son expression est la suivante :

$$\begin{aligned} R &= \frac{F_e}{2} \cdot l_1 + \frac{F_e}{2} \cdot l_2 \\ &= \frac{F_e}{2}(l_1 + l_2) \end{aligned} \tag{2.5}$$

l_1 : nombres de bits de quantification pour la sous-bande BF
l_2 : nombres de bits de quantification pour la sous-bande HF

Et donc le bit de retard s'exprime sous cette forme :

$$\begin{aligned}\text{Bits de retard} &= R.\tau \\ &= (\frac{F_e}{2}(l_1 + l_2)).\frac{N}{F_e} \\ &= N\frac{(l_1 + l_2)}{2}\end{aligned} \tag{2.6}$$

Etape 3 : Écoute du signal synthétisé.
L'écoute subjective du signal ss a été réalisée pour différentes combinaisons (l_1, l_2) correspondant au nombre de bits alloués à chaque sous-bande. Les conclusions sont les suivantes :

- Le signal synthétisé reste globalement intelligible, malgré une légère dégradation perceptuelle.
- La qualité perçue s'améliore lorsque la sous-bande basse fréquence (BF) reçoit un encodage plus précis.

Le couple $(l_1 = 8, l_2 = 4)$ permet de concilier bonne intelligibilité et complexité réduite, en limitant les distorsions audibles.

Etape 4 : Calcul du débit binaire et du RSB.
Le débit binaire total, exprimé en kbps, s'ecrit sous cette forme :

$$\text{débit} = (\frac{F_e}{M}.(l_1 + l_2))/1000 \tag{2.7}$$

$\frac{F_e}{M}$: échantillons/seconde après décimation.
$(l_1 + l_2)$: bits/échantillons.
Pour calucler les **RSB** entre le signal original et le signal synthétisé, on utilise la formule suivante :

$$RSB = 10 \cdot \log_{10}\left(\frac{E[s^2]}{E[(s - ss)^2]}\right) \tag{2.8}$$

Il quantifie la fidélité de la restitution du signal. Une comparaison a été faite pour plusieurs couples (l_1, l_2), et les résultats sont présentés ci-dessous.

l_1	l_2	Débit total (kbps)	RSB BF (dB)	RSB HF (dB)
2	2	16.0	1.3	1.2
4	4	32.0	16.7	7.4
8	4	48.0	39.9	7.4
12	4	64.0	63.7	7.4
8	8	64.0	39.9	32.5
12	12	96.0	63.7	57.0

TABLE 4 – Tableau de l'évolution du débit binaire total, du rapport signal sur bruit (RSB) pour les bandes de basse fréquence (BF) et haute fréquence (HF), en fonction des combinaisons de bits de quantification l_1 et l_2 alloués respectivement aux sous-bandes BF et HF.

Etape 5 : Choix final de (l_1, l_2).
En croisant les résultats objectifs (RSB et débit) et les observations subjectives (écoute), le couple $(l_1 = 8, l_2 = 4)$ se démarque par un excellent compromis :

— Il offre une excellente qualité pour la bande BF (RSB BF = 39.9 dB), tout en maintenant une qualité correcte pour la bande HF (RSB HF = 7.4 dB).

— Le débit total reste raisonnable (48 kbps), adapté aux contraintes de codage à bas débit.

Les combinaisons avec un l_2 plus élevé apportent une meilleure qualité HF, mais au prix d'un débit nettement plus élevé. Ainsi, prioriser la bande BF (porteuse de l'intelligibilité) est plus judicieux pour une bonne restitution perceptuelle du signal vocal.

Etape 6 : Validation finale par indicateur perceptif (STOI).
Le **STOI** (**S**hort-**T**ime **O**bjective **I**ntelligibility) est une mesure intrusive permettant d'évaluer l'intelligibilité d'un signal vocal dégradé par rapport à sa version originale. Dans notre cas, il s'applique aux signaux s (original) et ss (synthétisé). Basé sur une comparaison mathématique des contenus spectro-temporels des deux signaux, le STOI quantifie leur similarité de manière objective. Il vise à prédire la capacité d'un auditeur à comprendre un message vocal, sans avoir recours à des tests subjectifs coûteux ou longs. Ce score permet donc d'évaluer comment les traitements appliqués ou le bruit affectent la clarté perçue de la parole.[1]
Les étapes de calcul sont les suivantes :

1. **Initialisation des paramètres :**

- **win_len** : durée de trame fixée à **30 ms**. Elle permet de capturer les unités fondamentales de la parole (comme les phonèmes) tout en respectant la résolution temporelle de l'oreille humaine (20 à 40 ms).
- **win** : fenêtre de Hamming, utilisée pour atténuer les discontinuités aux extrémités des trames, réduisant ainsi les défauts sonores dans l'analyse fréquentielle.
- **step** : recouvrement de **50 %**. Chaque nouvelle trame démarre à la moitié de la précédente, assurant une transition fluide entre les segments du signal.
- **nfft** : taille de la FFT fixée à **256**, permettant une bonne résolution fréquentielle (62,5 Hz à 16 kHz) tout en maintenant une complexité de calcul raisonnable.

2. **Découpage en trames :**
   Les deux signaux (propre et dégradé) sont découpés en trames de 30 ms avec un recouvrement de 50%. Cette segmentation permet une analyse temps-fréquence fine, essentielle pour évaluer les variations locales du signal.
3. **Fenêtrage et analyse fréquentielle :**
   Chaque trame est multipliée par la fenêtre de Hamming, puis transformée dans le domaine fréquentiel à l'aide d'une transformée de Fourier rapide (FFT).
4. **Compression logarithmique :**
   Les magnitudes spectrales sont ensuite transformées par une fonction logarithmique. Ce traitement modélise la réponse non linéaire de l'audition humaine, qui perçoit les variations d'intensité sonore de manière logarithmique.
5. **Comparaison trame par trame :**
   Pour chaque paire de trames correspondantes (signal propre et dégradé), on calcule le coefficient de corrélation entre leurs spectres log-transformés. Ce coefficient mesure la similarité entre les deux signaux.
6. **Synthèse du score final :**
   Le score STOI final est obtenu en moyennant les coefficients de corrélation de toutes les trames. Il est compris entre 0 (intelligibilité nulle) et 1 (intelligibilité parfaite).

Score STOI	Interprétation
> 0.85	Excellente intelligibilité
$0.70 - 0.85$	Bonne intelligibilité
$0.50 - 0.70$	Intelligibilité moyenne
< 0.50	Intelligibilité faible

TABLE 5 – Interprétation du score STOI[3]

```
function score = simple_stoi(clean, degraded, fs)
    %Parametres
    win_len = round(0.03 * fs);
    win = hamming(win_len);
    step = round(win_len/2);
    nfft = 256;

    num_frames = floor((length(clean) - win_len)/step) + 1;
    corr_coeffs = zeros(num_frames, 1);

    %Decoupage en trames
    for i = 1:num_frames
        start_idx = (i-1)*step + 1;
        end_idx = start_idx + win_len - 1;
        %Fenetrage
        frame_clean = clean(start_idx:end_idx) .* win;
        frame_degraded = degraded(start_idx:end_idx) .* win;

        %Calcul des spectres
        spec_clean = abs(fft(frame_clean, nfft));
        spec_degraded = abs(fft(frame_degraded, nfft));

        %Correlation des magnitudes spectrales
        valid_idx = find(spec_clean > 0 & spec_degraded > 0);
        if numel(valid_idx) > 5
            corr_matrix = corrcoef(log(spec_clean(valid_idx)), log(spec_degraded(
                valid_idx)));
            corr_coeffs(i) = corr_matrix(1, 2);
        else
            corr_coeffs(i) = 0;
        end
    end

    score = mean(corr_coeffs);
end
```

Listing 2 – Script `Fonction Score d'intelligibilité`[2]

Le score STOI calculé entre le signal original et le signal synthétisée en utilisant la fonction Score 2 est de $\boxed{0.895}$. Selon le tableau 5, ce résultat indique une excellente intelligibilité du signal reconstitué. Il valide ainsi la qualité du système de codage/décodage implémenté, confirmant que les distorsions introduites au cours du traitement restent perceptuellement négligeables.

3 Conclusion

Ce projet nous a permis de concevoir, implémenter et évaluer une chaîne complète de compression et de décompression audio basée sur le codage en sous-bandes. À travers une architecture en cinq étapes (filtrage, décimation, quantification, interpolation et synthèse), nous avons reproduit un système de codage efficace visant à réduire le débit binaire tout en préservant l'intelligibilité du signal vocal. Les résultats obtenus, tant sur le plan objectif (RSB, débit binaire) que subjectif (écoute, intelligibilité), confirment la pertinence des choix techniques effectués. Le recours aux filtres RIF à phase linéaire a notamment permis une reconstruction fidèle du signal, et l'analyse comparative entre différentes valeurs de quantification a mis en évidence l'importance d'une répartition judicieuse des bits entre bandes fréquentielles. L'intelligibilité du signal reconstruit a été validée par le score STOI, qui a atteint une valeur de 0,895, témoignant d'une excellente qualité perçue. Ce projet a ainsi concrétisé les principaux enseignements du module de traitement du signal, tout en offrant une expérience complète allant de la théorie à la mise en œuvre pratique.
Des perspectives d'amélioration pourraient inclure l'implémentation d'un codage entropique plus sophistiqué, l'extension à un banc de filtres multi-bandes, ou encore l'intégration d'outils d'évaluation perceptive plus avancés. Ce travail pose ainsi les bases d'un codage audio efficace, tout en ouvrant la voie à des développements futurs dans le domaine de la compression vocale.

Références

[1] MathWorks. *Measure Speech Intelligibility and Perceived Audio Quality with STOI and ViSQOL*. MathWorks, 2024. Accessed : 2025-05-30.

[2] mpariente. Python implementation of stoi. https ://github.com/mpariente/pystoi/blob/master/README.md, 2025. Consulté le 28 Mai 2025.

[3] Carl Hopkins Simone Graetzer. Intelligibility prediction for speech mixed with white gaussian noise at low signal-to-noise ratios. 2021.