École Nationale Supérieure d'Informatique pour l'Industrie et l'Entreprise

The Quintic Ornstein-Uhlenbeck Volatility Model that Jointly Calibrates SPX & VIX Smiles

Réalisé par :

Bejaoui Saad Eddine

Dey Chadi

Kamoun Mariem

Encadré par :

Pulido Nino Sergio

2ème Année MA

Année Universitaire : 2025–2026

Table des matières

Introduction Générale **4**

1 Fondements théoriques **6**
1.1 Motivation 6
1.1.1 La flexibilité : 6
1.1.2 La tractabilité : 7
1.2 Le Modèle Quintic Ornstein-Uhlenbeck 7
1.2.1 Le processus de base : l'Ornstein-Uhlenbeck (OU) 7
1.2.2 Dynamique du prix et structure de la volatilité 8
1.2.3 Interprétation des paramètres 9
1.3 Pricing des dérivés du VIX : Dérivation Rigoureuse 10
1.3.1 Définition et structure intégrale 10
1.3.2 Expression de la variance forward $\xi_T(u)$ 11
1.3.3 Résultat central : Le VIX² polynomial 12
1.3.4 Pricing des options VIX 13
1.4 Pricing du SPX : 13
1.4.1 Schéma de simulation exacte 13
1.4.2 Réduction au calcul Black-Scholes (Conditionnement de Willard) 14
1.4.3 L'estimateur Monte Carlo final 16
1.4.4 Techniques complémentaires de réduction de variance 17
1.5 Calibration Conjointe SPX/VIX 17
1.5.1 Formulation du problème de calibration 17
1.5.2 Extraction de la courbe de variance forward ξ_0 18
1.5.3 Forme paramétrique de ξ_0 19
1.5.4 Extension : paramétrisation temporelle de H 19

2 Mise en oeuvre algorithmique **21**
2.1 Utilitaires mathématiques 21
2.1.1 Formule de Black-Scholes : `bs_price_call` 21
2.1.2 Volatilité implicite par dichotomie : `bs_iv_bisection` . . . 22
2.1.3 Évaluation polynomiale efficace : `horner_vector` 22

2.1.4 Double factorielle : `double_factorial` 22
2.1.5 Génération des chemins browniens : `def_bm_path` 23
2.1.6 Densité gaussienne : `gauss_dens` 23
2.1.7 Règle de filtrage du log-moneyness SPX : `spx_lm_range_rule` 23
2.2 Prétraitement et variance forward 24
2.2.1 Nettoyage des options SPX : `preprocess_spx` 24
2.2.2 Estimation des forwards VIX : `estimate_vix_forwards` . . 24
2.2.3 Filtrage des données VIX : `preprocess_vix` 25
2.2.4 Sélection des tranches de maturité : `select_slices` 25
2.2.5 Extraction de la variance forward : `extract_forward_variance` 25
2.3 Pricing SPX : Monte Carlo et turbocharging 26
2.3.1 Extension à un Hurst variable : `mc_spx_timedepth` 26
2.4 Pricing VIX : quadrature de Gauss-Legendre 27
2.4.1 Algorithme de pricing 27
2.5 Calibration jointe SPX/VIX 28
2.5.1 Fonction objectif et pondération 28
2.5.2 Stratégie d'optimisation 28
2.5.3 Phase 1 : variance forward par spline (`calibrate_spline`) . 29
2.5.4 Phase 2 : variance forward paramétrique (`calibrate_parametric`) 29
2.5.5 Phase 3 : Hurst variable (`calibrate_timedepH`) 29
2.6 Visualisation des smiles et interprétation des résultats 30
2.6.1 Variance forward du marché (Carr-Madan) 31
2.6.2 Phase 2 — ξ_0 paramétrique 31
2.6.3 Phase 1 — ξ_0 spline 33
2.6.4 Phase 3 — $H(t)$ variable 34
2.7 Limites du modèle 36
2.7.1 Non-convexité de la fonction objectif 36
2.7.2 Fixation arbitraire des coefficients c_1, c_2, c_3 36
2.7.3 Non-prise en compte des périodes de stress et de crise 37
2.8 Synthèse 37

3 Limites et pistes de réflexion 39
3.1 Motivation et limites du modèle Quintic OU 39
3.1.1 Rappel du modèle et de sa calibration 39
3.1.2 Limites identifiées : le coût computationnel du Monte Carlo 39
3.2 Les réseaux de neurones pour le pricing : contexte 40
3.2.1 Différents rôles possibles 40
3.2.2 Positionnement dans la littérature 41
3.3 Notre approche : choix et justification 41
3.3.1 Le réseau de neurones comme émulateur du Monte Carlo . . 41
3.3.2 Justification du choix 42

3.4 Mise en œuvre 42
3.4.1 Principe général et pipeline 42
3.4.2 Génération et description du dataset 43
3.4.3 Architecture et entraînement 46
3.5 Résultats 48
3.5.1 Performance d'émulation : le MLP comme substitut du Monte Carlo 48
3.5.2 Analyse des résidus sur le jeu d'entrainement 49
3.5.3 Comparaison visuelle avec le marché : smiles SPX 51
3.5.4 Généralisation sur le jeu de test 51

Conclusion Générale **53**

Bibliographie **54**

Introduction Générale

L'évaluation des dérivés financiers et la gestion des risques de marché reposent de manière cruciale sur la capacité des modèles à capturer la dynamique jointe de l'indice de référence S&P 500 (SPX) et de son indice de volatilité associé, le VIX. Historiquement, cette modélisation conjointe a donné naissance à ce que la littérature appelle le *"Joint Calibration Puzzle"* [4], caractérisé par la difficulté persistante à reproduire simultanément le smile de volatilité très marqué du SPX (notamment sur les maturités courtes) et les niveaux élevés de volatilité implicite des options sur VIX.
Les modèles classiques de volatilité stochastique, tels que le modèle de Heston, échouent généralement à produire un skew suffisamment pentu pour le SPX sans dégrader la dynamique du VIX. À l'opposé, les modèles de volatilité rugueuse (*Rough Volatility*), bien qu'extrêmement performants pour ajuster les sourires de volatilité, introduisent une complexité numérique non négligeable due à leur nature non-markovienne et à l'absence de solutions fermées pour le pricing du VIX.

Dans ce contexte, le modèle **Quintic Ornstein-Uhlenbeck (Quintic OU)**, introduit par Abi Jaber, Illand et Li (2023) [1], émerge comme une solution novatrice et élégante. Ce modèle repose sur une approche polynomiale de degré cinq appliquée à un unique processus d'Ornstein-Uhlenbeck. La force de cette spécification réside dans sa capacité à imiter le comportement des modèles rugueux grâce à un régime de retour à la moyenne très rapide et une forte volatilité de la volatilité, tout en restant strictement ancrée dans un cadre markovien. Cette propriété garantit une tractabilité mathématique remarquable, permettant d'obtenir des formules quasi-fermées pour les dérivés du VIX et une simulation exacte du processus de volatilité.

L'objectif de ce projet est d'explorer les propriétés théoriques et numériques de ce modèle afin d'en évaluer la pertinence pratique pour un bureau de trading ou de gestion de risques. Pour ce faire, notre étude s'articulera autour de trois axes principaux :

— **Les fondements théoriques :** Nous détaillerons le cadre mathématique

du processus Quintic OU, en mettant l'accent sur le calcul de l'espérance conditionnelle du VIX et la justification de la structure polynomiale.

— **La mise en œuvre algorithmique :** Nous exposerons les techniques de simulation de Monte Carlo "turbochargées", incluant le conditionnement par rapport à la filtration du mouvement brownien de la volatilité et l'utilisation de variables de contrôle pour optimiser la convergence du pricing du SPX.

— **Pistes de réflexion :** Enfin, nous conclurons par une analyse critique du modèle, en discutant notamment des extensions possibles vers des paramètres dépendant du temps pour affiner le calage sur de longues maturités.

Chapitre 1

Fondements théoriques

1.1 Motivation

Le choix du modèle Quintic Ornstein-Uhlenbeck est motivé par la nécessité de réconcilier deux impératifs souvent antagonistes en modélisation financière : la capacité à reproduire des dynamiques de marché complexes (flexibilité) et la facilité de mise en œuvre numérique pour le pricing en temps réel (tractabilité).

1.1.1 La flexibilité :

L'un des défis majeurs pour tout modèle de volatilité stochastique est de capturer le *skew* de volatilité très prononcé des options SPX à court terme. Les modèles classiques (type Heston) produisent un skew qui s'aplatit trop rapidement lorsque la maturité tend vers zéro, à moins d'utiliser des paramètres de "vol-of-vol" extrêmes qui brisent la stabilité du modèle.

À l'inverse, les modèles de volatilité rugueuse (*Rough Volatility*) parviennent à fitter ce skew grâce à un noyau fractionnaire. Cependant, le modèle Quintic OU propose une alternative élégante en restant dans un cadre brownien standard. Sa flexibilité provient de deux leviers :

— **Paramétrage à haute intensité :** En introduisant un paramètre de retour à la moyenne κ très élevé (via un paramètre ϵ petit), le modèle permet au processus de "sauter" rapidement, mimant ainsi le comportement explosif de la volatilité rugueuse.

— **Structure polynomiale de degré 5 :** Contrairement aux modèles de volatilité log-normale, la forme quintique permet de donner beaucoup plus de poids aux queues de distribution. Cela offre une liberté supplémentaire pour ajuster la convexité du smile du VIX sans impacter négativement celui du SPX.

1.1.2 La tractabilité :

La force du modèle réside dans le fait que cette flexibilité accrue ne se fait pas au détriment de la vitesse de calcul. Le compromis est ici résolu par la préservation du caractère markovien et polynomial :

1. **Pricing du VIX par quadrature :** Puisque la variance instantanée est un polynôme du processus d'Ornstein-Uhlenbeck (OU) et que le processus OU est gaussien, le calcul du VIX se réduit à une simple intégrale contre une densité normale. Il n'est pas nécessaire de recourir à des simulations de Monte Carlo coûteuses pour obtenir les prix des options sur VIX.
2. **Simulation exacte :** Le processus X_t étant un processus OU, sa simulation sur une grille de temps est exacte (on tire directement dans la loi normale conditionnelle). Il n'y a donc pas de biais de discrétisation (type schéma d'Euler), ce qui renforce la fiabilité des résultats.
3. **Réduction de variance "Turbocharged" :** Comme nous le verrons dans la partie algorithmique, la structure du modèle permet d'utiliser des variables de contrôle très puissantes et des techniques de conditionnement (loi log-normale conditionnelle) qui réduisent drastiquement le bruit de simulation.

1.2 Le Modèle Quintic Ornstein-Uhlenbeck

Le modèle Quintic OU repose sur la dynamique d'un unique processus stochastique sous-jacent, dont la transformation polynomiale définit la volatilité instantanée du prix des actifs. Cette section détaille la construction de ce processus et la spécification du modèle de volatilité.

1.2.1 Le processus de base : l'Ornstein-Uhlenbeck (OU)

Le cœur du modèle est un processus d'Ornstein-Uhlenbeck (OU) noté $(X_t)_{t\geq 0}$, solution de l'équation différentielle stochastique (EDS) suivante :

$$\begin{cases} dX_t = -\kappa X_t \, dt + \eta \, dW_t \\ X_0 = 0 \end{cases}$$

W : est un mouvement brownien standard.
$\kappa = \frac{1/2-H}{\epsilon}$: vitesse de retour à la moyenne.
$\eta = \epsilon^{H-1/2}$: volatilité du processus.

Résolution exacte et propriété gaussienne

Pour résoudre cette EDS, nous utilisons la méthode du facteur intégrant en posant $Y_t = e^{\kappa t} X_t$. Par la formule d'Itô, nous avons :

$$\begin{aligned} dY_t &= \kappa e^{\kappa t} X_t \, dt + e^{\kappa t} dX_t \\ &= \kappa e^{\kappa t} X_t \, dt + e^{\kappa t} \left(-\kappa X_t \, dt + \eta \, dW_t\right) \\ &= \eta e^{\kappa t} \, dW_t \end{aligned}$$

En intégrant entre 0 et t et en multipliant par $e^{-\kappa t}$, on obtient l'expression exacte de X_t :

$$\begin{aligned} X_t &= \eta \int_0^t e^{-\kappa(t-s)} \, dW_s \\ &= \epsilon^{H-1/2} \int_0^t e^{-(1/2-H)\epsilon^{-1}(t-s)} \, dW_s \end{aligned}$$

Le processus X_t gaussien comme une intégrale d'Itô d'un intégrande déterministe. Ses moments sont :

$$\begin{cases} \mathbb{E}[X_t] = 0 & \text{(propriété de martingale de l'intégrale d'Itô)} \\ \mathrm{Var}(X_t) & \text{(par l'isométrie d'Itô)} \end{cases}$$

$$\begin{aligned} \sigma_{X_t}^2 &= \mathrm{Var}(X_t) \\ &= \int_0^t \eta^2 e^{-2\kappa(t-s)} \, ds \\ &= \eta^2 \frac{1 - e^{-2\kappa t}}{2\kappa} \end{aligned}$$

En substituant κ et η, nous isolons la variance théorique du modèle :

$$X_t \sim \mathcal{N}\left(0, \frac{\epsilon^{2H}}{1-2H}\left(1 - e^{-(1-2H)\epsilon^{-1}t}\right)\right) \tag{1.2.1}$$

1.2.2 Dynamique du prix et structure de la volatilité

Le modèle complet pour le prix de l'actif $(S_t)_{t\geq 0}$ sous la mesure risquenard est défini par :

$$\frac{dS_t}{S_t} = \sigma_t \, dB_t \tag{1.2.2}$$

$$\sigma_t = \xi_0(t) \frac{p(X_t)^2}{\mathbb{E}[p(X_t)^2]} \tag{1.2.3}$$

$dB_t := \mathrm{dW}_t + \sqrt{1-\rho^2}\, dW_t^{\perp}$.(W,W$^{\perp}$) mouvement brownien de dimension 2.
ρ : la corrélation entre les rendements et la volatilité (effet levier) $\in [-1, 1]$.
$\xi_0(t)$: courbe forward variance curve.

Le polynôme Quintique

Afin de capturer l'asymétrie et la courbure des smiles tout en conservant une structure paramétrique parcimonieuse, la fonction p est définie comme un polynôme de degré 5 ne comportant que des puissances impaires :

$$p(x) = \alpha_0 + \alpha_1 x + \alpha_3 x^3 + \alpha_5 x^5 \tag{1.2.4}$$

Ce choix spécifique est crucial pour plusieurs raisons :

— **Positivité garantie :** La variance $\sigma_t \propto \mathrm{p(X}_t)^2$, elle reste intrinsèquement strictement positive, sans nécessiter de contraintes complexes sur les coefficients α_i.

— **Flexibilité du Smile :** Les puissances impaires permettent de générer une réponse asymétrique de la volatilité face aux chocs du processus X_t, ce qui est indispensable pour reproduire le *skew* observé sur les marchés.

— **Tractabilité des moments :** Puisque p est impair, son carré p^2 ne contient que des puissances paires $(x^0, x^2, \ldots, x^{10})$. Cela simplifie considérablement le calcul de la constante de normalisation $\mathbb{E}[p(X_t)^2]$ et des moments du VIX, car l'espérance des puissances impaires d'une variable gaussienne centrée est nulle.

1.2.3 Interprétation des paramètres

Le modèle est piloté par un ensemble de variables ayant chacune une utilité structurelle précise. Nous pouvons résumer leurs rôles respectifs de la manière suivante :

$$\begin{cases} H \in (-\infty, 1/2) & \text{: Indice de régularité (imite la rugosité du skew court terme)} \\ \epsilon > 0 & \text{: Échelle de temps (pilote la vitesse de retour à la moyenne } \kappa) \\ \rho \in [-1, 1] & \text{: Corrélation rendement-volatilité (génère l'asymétrie du smile)} \\ \alpha_0, \ldots, \alpha_5 & \text{: Coefficients polynomiaux (ajustent la convexité du smile du VIX)} \\ \xi_0(t) & \text{: Courbe forward (permet le calage de la structure par terme)} \end{cases}$$

L'intérêt majeur : Grâce à la gaussienneté de X_t, toute espérance de la forme $\mathbb{E}[\phi(VIX_T)]$ (nécessaire pour le pricing du VIX) devient une intégrale simple sur une densité normale, ce qui assure une tractabilité sans égal pour le calibrage.

1.3 Pricing des dérivés du VIX : Dérivation Rigoureuse

Le succès du modèle Quintic OU repose sur sa capacité à exprimer le VIX comme une fonction polynomiale du processus d'état X_T. Cette section détaille le passage de la définition continue du VIX à une formule de pricing par quadrature unidimensionnelle.

1.3.1 Définition et structure intégrale

Le VIX est construit à partir de la réplication du log-contrat. Pour un horizon de $\Delta = 30/365$ ans, sa définition en temps continu à l'instant T est donnée par :

$$\mathrm{VIX}_T^2 = \frac{-2}{\Delta}\,\mathbb{E}^{\mathcal{F}_T}\left[\log\frac{S_{T+\Delta}}{S_T}\right] \times 100^2 \tag{3.1}$$

Afin de développer cette expression, nous appliquons la formule d'Itô à la dynamique du prix S_t. En supposant une dynamique sans dérive de la forme $dS_t/S_t = \sigma_t dB_t$, on obtient sur l'intervalle $[T, T+\Delta]$:

$$\log S_{T+\Delta} - \log S_T = \int_T^{T+\Delta} \sigma_t\, dB_t - \frac{1}{2}\int_T^{T+\Delta} \sigma_t^2\, dt$$

En prenant l'espérance conditionnelle par rapport à la filtration $\mathcal{F}_T$, et en remarquant que l'intégrale stochastique par rapport au mouvement brownien dB_t est une martingale (son espérance conditionnelle est donc nulle), il vient :

$$\begin{aligned}
\mathbb{E}^{\mathcal{F}_T}\left[\log\left(\frac{S_{T+\Delta}}{S_T}\right)\right] &= \mathbb{E}^{\mathcal{F}_T}\left[\int_T^{T+\Delta} \sigma_t\, dB_t - \frac{1}{2}\int_T^{T+\Delta} \sigma_t^2\, dt\right] \\
&= 0 - \frac{1}{2}\mathbb{E}^{\mathcal{F}_T}\left[\int_T^{T+\Delta} \sigma_t^2\, dt\right] \\
&= -\frac{1}{2}\int_T^{T+\Delta} \mathbb{E}^{\mathcal{F}_T}\left[\sigma_t^2\right] dt \\
&= -\frac{1}{2}\int_T^{T+\Delta} \xi_T(t)\, dt
\end{aligned}$$

avec $\xi_T(t) := \mathbb{E}^{\mathcal{F}_T}[\sigma_t^2]$ la variance forward conditionnelle.
En réinjectant ce résultat fondamental dans l'équation de définition (3.1), nous obtenons la forme intégrale du VIX au carré :

$$\mathrm{VIX}_T^2 = \frac{100^2}{\Delta} \int_T^{T+\Delta} \xi_T(t)\, dt \tag{3.2}$$

1.3.2 Expression de la variance forward $\xi_T(u)$

Dans notre modèle, la variance instantanée est donnée par $\sigma_u^2 = \xi_0(u)\frac{P(X_u)^2}{g(u)}$, avec la constante de normalisation $g(u) = \mathbb{E}[P(X_u)^2]$. L'enjeu est donc de calculer $\mathbb{E}^{\mathcal{F}_T}[P(X_u)^2]$.

Pour $u \geq T$, nous exploitons la structure auto-régressive du processus d'Ornstein-Uhlenbeck pour décomposer X_u. En séparant la partie connue en T de l'innovation stochastique future, nous avons :

$$\begin{aligned}
X_u &= \varepsilon^{H-1/2} \int_0^u e^{-(1/2-H)\varepsilon^{-1}(u-s)} dW_s \\
&= \varepsilon^{H-1/2} \int_0^T e^{-(1/2-H)\varepsilon^{-1}(u-s)} dW_s + \varepsilon^{H-1/2} \int_T^u e^{-(1/2-H)\varepsilon^{-1}(u-s)} dW_s \\
&= \underbrace{X_T e^{-(1/2-H)\varepsilon^{-1}(u-T)}}_{Z_T^u} + \underbrace{\varepsilon^{H-1/2} \int_T^u e^{-(1/2-H)\varepsilon^{-1}(u-s)} dW_s}_{G_T^u}
\end{aligned}$$

Cette décomposition $X_u = Z_T^u + G_T^u$ possède des propriétés fondamentales pour la suite des calculs :

- Z_T^u est $\mathcal{F}_T$-mesurable (totalement déterminé par l'information disponible en T).
- G_T^u est indépendant de $\mathcal{F}_T$ (en vertu de la propriété des accroissements indépendants du mouvement brownien) et suit une loi gaussienne centrée dont la variance analytique est :

$$\sigma_G^2(u,T) = \frac{\epsilon^{2H}}{1-2H}\left(1 - e^{-(1-2H)\epsilon^{-1}(u-T)}\right) \tag{3.4}$$

Considérons à présent le développement du polynôme de volatilité au carré. En notant $(\alpha * \alpha)_k$ le produit de convolution discret des coefficients α, on obtient :

$$p(x)^2 = \left(\sum_{k=0}^{10} \alpha_k x^k\right)^2 = \sum_{k=0}^{10} (\alpha * \alpha)_k x^k$$

Par linéarité de l'espérance conditionnelle, et en appliquant la formule du binôme de Newton à $(Z_T^u + G_T^u)^k$, nous pouvons développer l'espérance du polynôme. Sachant que Z_T^u sort de l'espérance et que G_T^u en est indépendant, nous avons :

$$\begin{aligned}
\mathbb{E}^{\mathcal{F}_T}\left[p^2(X_u)\right] &= \mathbb{E}^{\mathcal{F}_T}\left[\sum_{k=0}^{10}(\alpha * \alpha)_k X_u^k\right] \\
&= \sum_{k=0}^{10}(\alpha * \alpha)_k \mathbb{E}^{\mathcal{F}_T}\left[X_u^k\right] \\
&= \sum_{k=0}^{10}(\alpha * \alpha)_k \mathbb{E}^{\mathcal{F}_T}\left[\sum_{i=0}^{k} C_k^i \left(Z_T^u\right)^i \left(G_T^u\right)^{k-i}\right] \\
&= \sum_{k=0}^{10}(\alpha * \alpha)_k \sum_{i=0}^{k} C_k^i \left(Z_T^u\right)^i \mathbb{E}\left[\left(G_T^u\right)^{k-i}\right] \\
&= \sum_{k=0}^{10}(\alpha * \alpha)_k \sum_{i=0}^{k} C_k^i e^{-(1/2-H)\varepsilon^{-1}i(u-T)} X_T^i \mathbb{E}\left[\left(G_T^u\right)^{k-i}\right] \\
&= \sum_{i=0}^{10}\left(\sum_{k=i}^{10}(\alpha * \alpha)_k C_k^i e^{-(1/2-H)\varepsilon^{-1}i(u-T)} \mathbb{E}\left[\left(G_T^u\right)^{k-i}\right]\right) X_T^i
\end{aligned}$$

En substituant cette dernière expression dans la définition de la variance forward conditionnelle, nous isolons clairement le polynôme en X_T :

$$\begin{aligned}
\xi_T(u) &= \frac{\xi_0(u)}{g(u)} \mathbb{E}^{\mathcal{F}_T}\left[p^2(X_u)\right] \\
&= \frac{\xi_0(u)}{g(u)} \sum_{i=0}^{10}\left(\sum_{k=i}^{10}(\alpha * \alpha)_k C_k^i e^{-(1/2-H)\varepsilon^{-1}i(u-T)} \mathbb{E}\left[\left(G_T^u\right)^{k-i}\right]\right) X_T^i
\end{aligned}$$

1.3.3 Résultat central : Le VIX² polynomial

Il convient de rappeler que les moments d'une variable gaussienne centrée G_T^u s'expriment analytiquement à l'aide de sa variance définie en (3.4) :

$$\mathbb{E}[(G_T^u)^m] = \begin{cases} 0 & \text{si } m \text{ est impair} \\ \sigma_G^m(u,T) \cdot (m-1)!! & \text{si } m \text{ est pair} \end{cases} \tag{3.7}$$

En revenant à l'équation intégrale du VIX (3.2), et en substituant $\xi_T(u)$ par sa forme développée, nous pouvons utiliser le théorème de Fubini pour intervertir les sommes et l'intégrale temporelle. Puisque X_T^i est $\mathcal{F}_T$-mesurable, il peut être

factorisé en dehors de l'intégrale :

$$\begin{aligned}
\mathrm{VIX}_T^2 &= \frac{100^2}{\Delta}\int_T^{T+\Delta}\sum_{i=0}^{10}\sum_{k=i}^{10}\frac{\xi_0(u)}{g(u)}(\alpha*\alpha)_k C_k^i e^{-(1/2-H)\varepsilon^{-1}i(u-T)}\mathbb{E}\left[(G_T^u)^{k-i}\right]X_T^i\,du \\
&= \sum_{i=0}^{10}\left(\frac{100^2}{\Delta}\sum_{k=i}^{10}(\alpha*\alpha)_k C_k^i\int_T^{T+\Delta}\frac{\xi_0(u)}{g(u)}e^{-(1/2-H)\varepsilon^{-1}i(u-T)}\mathbb{E}\left[(G_T^u)^{k-i}\right]du\right)X_T^i \\
&= \sum_{i=0}^{10}\beta_i X_T^i
\end{aligned}$$

Le VIX au carré est donc un simple polynôme en X_T où les coefficients β_i sont des constantes déterministes (en posant $\kappa = (1/2-H)\varepsilon^{-1}$ et $\gamma_k = (\alpha*\alpha)_k$ pour alléger la notation) calculables par quadrature :

$$\beta_i = \frac{100^2}{\Delta}\sum_{k=i}^{10}\gamma_k\binom{k}{i}\int_T^{T+\Delta}\frac{\xi_0(u)}{g(u)}e^{-\kappa i(u-T)}\mathbb{E}[(G_T^u)^{k-i}]\,du \tag{3.10}$$

1.3.4 Pricing des options VIX

La conséquence immédiate de l'équation (3.10) est que le VIX s'exprime comme la racine d'un polynôme $h(X_T) = \sum_{i=0}^{10}\beta_i X_T^i$. Le prix de tout dérivé du VIX de payoff Φ se réduit ainsi à une espérance sur la loi gaussienne de $X_T \sim \mathcal{N}(0,\sigma_{X_T}^2)$:

$$\mathbb{E}[\Phi(\mathrm{VIX}_T)] = \int_{-\infty}^{+\infty}\Phi\left(\sqrt{h(x)}\right)\frac{1}{\sqrt{2\pi\sigma_{X_T}^2}}e^{-\frac{x^2}{2\sigma_{X_T}^2}}\,dx \tag{3.12}$$

Cette intégrale unidimensionnelle est calculable numériquement quasi-instantanément et permet d'éviter l'usage coûteux des simulations de Monte Carlo pour le calibrage.

1.4 Pricing du SPX :

Le pricing des options sur SPX dans le modèle Quintic OU repose sur une technique de réduction de variance par conditionnement, exploitant la structure gaussienne du processus de volatilité.

1.4.1 Schéma de simulation exacte

Contrairement à de nombreux modèles de volatilité stochastique, le processus d'état X peut être simulé de manière exacte sans biais de discrétisation temporelle

(pas de schéma d'Euler nécessaire pour X). Pour une grille de temps $0 = t_0 < t_1 < \cdots < t_n = T$, nous utilisons la propriété de Markov :

$$X_{t_{i+1}} = X_{t_i} e^{-\kappa \Delta t} + \sigma_G(t_{i+1}, t_i) Z_{i+1}, \quad Z_{i+1} \sim \mathcal{N}(0,1) \tag{1.4.1}$$

Cette exactitude garantit que la seule source d'erreur numérique provient de la variance de l'estimateur de Monte Carlo et non de la discrétisation du processus de volatilité.

1.4.2 Réduction au calcul Black-Scholes (Conditionnement de Willard)

La technique de réduction de variance repose sur la log-normalité conditionnelle du prix. L'objectif est d'exprimer l'espérance du payoff d'un Call comme une formule de Black-Scholes appliquée analytiquement à chaque trajectoire simulée du mouvement brownien W [2].

Origine de la log-normalité de $S_T \mid \mathcal{F}_T^W$

En posant $\Sigma = \int_0^T \sigma_t^2 \, dt$ (la variance réalisée cumulée), nous décomposons cette expression :

$$\log S_T = \underbrace{\log S_0 - \frac{1}{2}\rho^2 \Sigma + \rho \int_0^T \sigma_t \, dW_t}_{\log S_T^W} \underbrace{- \frac{1}{2}(1-\rho^2)\Sigma + \sqrt{1-\rho^2} \int_0^T \sigma_t \, dW_t^{\perp}}_{R} \tag{1.4.2}$$

Puisque σ_t est $\mathcal{F}_T^W$-mesurable, conditionnellement à cette filtration :

1. S_T^W et Σ sont des constantes déterministes.
2. Le terme résiduel R est une intégrale de Wiener à intégrande déterministe, donc $R \sim \mathcal{N}\left(-\frac{1}{2}(1-\rho^2)\Sigma, (1-\rho^2)\Sigma\right)$.

Il en résulte que la loi conditionnelle est normale :

$$\log S_T \mid \mathcal{F}_T^W \sim \mathcal{N}\left(\underbrace{\log S_T^W - \frac{1}{2}(1-\rho^2)\Sigma}_{\mu}, \underbrace{(1-\rho^2)\Sigma}_{\nu^2} \right)$$

Le prix S_T suit donc une loi log-normale conditionnelle que l'on peut écrire sous la forme :

$$S_T \mid \mathcal{F}_T^W \stackrel{d}{=} e^{\mu + \nu Z}, \quad \text{avec } Z \sim \mathcal{N}(0,1) \perp \mathcal{F}_T^W$$

On remarque directement que la constante se réécrit $e^{\mu} = S_T^W e^{-\frac{\nu^2}{2}}$.
Calculons le moment d'ordre 1 sous cette mesure conditionnelle :

$$\begin{aligned}
\mathbb{E}\left[S_T \mid \mathcal{F}_T^W\right] &= \mathbb{E}\left[e^{\mu+\nu Z} \mid \mathcal{F}_T^W\right] \\
&= e^{\mu+\frac{\nu^2}{2}} \\
&= \exp\left(\log S_T^W - \frac{1}{2}(1-\rho^2)\Sigma + \frac{1}{2}(1-\rho^2)\Sigma\right) \\
&= S_T^W
\end{aligned}$$

Ainsi, S_T^W joue rigoureusement le rôle du prix *forward* conditionnel de S_T sachant le chemin W.

Calcul de l'espérance du Call européen

Fort de cette distribution, le prix conditionnel du Call devient l'espérance de sa partie positive :

$$\mathbb{E}\left[(S_T - K)^+ \mid \mathcal{F}_T^W\right] = \int_{\mathbb{R}} \left(e^{\mu+\nu z} - K\right)^+ \frac{e^{-\frac{z^2}{2}}}{\sqrt{2\pi}} dz$$

Déterminons l'intervalle d'intégration pour lequel le flux est dans la monnaie (strictement positif) :

$$\begin{aligned}
e^{\mu+\nu z} - K > 0 &\iff e^{\mu+\nu z} > K \\
&\iff \mu + \nu z > \log K \\
&\iff z > \frac{\log K - \mu}{\nu}
\end{aligned}$$

En posant $d_2 = \frac{\mu - \log K}{\nu}$, la borne inférieure d'intégration devient $-d_2$. Nous pouvons alors scinder l'intégrale en deux parties :

$$\mathbb{E}\left[(S_T - K)^+ \mid \mathcal{F}_T^W\right] = \int_{-d_2}^{+\infty} e^{\mu+\nu z} \frac{e^{-\frac{z^2}{2}}}{\sqrt{2\pi}} dz - \underbrace{\int_{-d_2}^{+\infty} K \frac{e^{-\frac{z^2}{2}}}{\sqrt{2\pi}} dz}_{=K\mathcal{N}(d_2)}$$

Pour évaluer le premier terme, nous complétons le carré dans l'argument de l'exponentielle :

$$\mu + \nu z - \frac{z^2}{2} = -\frac{1}{2}(z-\nu)^2 + \underbrace{\mu + \frac{\nu^2}{2}}_{=\log S_T^W}$$

Ce qui nous permet de résoudre l'intégrale par un simple changement de variable ($u = z - \nu$) :

$$\begin{aligned}
\int_{-d_2}^{+\infty} e^{\mu+\nu z} \frac{e^{-\frac{z^2}{2}}}{\sqrt{2\pi}} dz &= e^{\mu+\frac{\nu^2}{2}} \int_{-d_2}^{+\infty} \frac{e^{-\frac{1}{2}(z-\nu)^2}}{\sqrt{2\pi}} dz \\
&= S_T^W \int_{-d_2-\nu}^{+\infty} \frac{e^{-\frac{u^2}{2}}}{\sqrt{2\pi}} du \\
&= S_T^W \mathcal{N}(d_2 + \nu) \\
&= S_T^W \mathcal{N}(d_1)
\end{aligned}$$

avec $d_1 = d_2 + \nu$.

Conclusion

En regroupant les termes calculés, l'espérance du payoff se ramène exactement à la formule analytique de Black-Scholes, où la variance totale est donnée par la part non expliquée par W, à savoir $(1 - \rho^2)\Sigma$:

$$\begin{aligned}
\mathbb{E}\left[(S_T - K)^+ \mid \mathcal{F}_T^W\right] &= S_T^W \mathcal{N}(d_1) - K\mathcal{N}(d_2) \\
&= \mathrm{BS}\left(S_T^W, \sqrt{\frac{(1-\rho^2)\Sigma}{T}}, T, K\right)
\end{aligned}$$

Cette approche justifie de substituer une simulation bruitée du Brownien orthogonal par une évaluation analytique directe, réduisant ainsi drastiquement la variance de l'estimateur de Monte Carlo.

1.4.3 L'estimateur Monte Carlo final

Le prix de l'option est obtenu par la loi de l'espérance totale (propriété de la tour) :

$$\begin{aligned}
C_0 &= \mathbb{E}\left[(S_T - K)^+\right] \\
&= \mathbb{E}\left[\mathbb{E}\left[(S_T - K)^+ / \mathcal{F}_T^W\right]\right] \\
&= \mathbb{E}[\mathrm{BS}(S_T^W, v, T, K)] \\
&\approx \frac{1}{N} \sum_{n=1}^{N} \mathrm{BS}\left(S_T^{W,(n)}, v^{(n)}, T, K\right)
\end{aligned}$$

1.4.4 Techniques complémentaires de réduction de variance

Pour affiner davantage la convergence, deux techniques sont couplées à cet estimateur :

— **Variables Anthitétiques :** Pour chaque trajectoire simulée du brownien W, nous calculons également le prix pour la trajectoire $-W$. L'estimateur est la moyenne des deux, ce qui élimine les termes d'ordre impair dans l'erreur de simulation.

— **Variables de Contrôle :** est une technique de réduction de variance en simulation Monte Carlo. Elle consiste à introduire une quantité auxiliaire corrélée à la quantité d'intérêt, dont l'espérance est connue analytiquement, afin de corriger l'estimateur brut et d'obtenir un estimateur non biaisé de variance réduite.

L'alliance du conditionnement et de ces techniques permet d'obtenir des smiles de volatilité extrêmement lisses avec seulement 10^4 ou 10^5 trajectoires, là où un Monte Carlo brut en nécessiterait des millions.

1.5 Calibration Conjointe SPX/VIX

Les sections précédentes ont établi les outils de pricing nécessaires : une quadrature quasi-fermée pour les dérivés du VIX (Section 3) et un estimateur Monte Carlo à variance réduite pour les options SPX (Section 4). Ces deux briques constituent précisément les ingrédients dont nous avons besoin pour résoudre le problème central du modèle Quintic OU : la *calibration conjointe* sur les surfaces de volatilité du SPX et du VIX. Cette section détaille la formulation mathématique de ce problème d'optimisation ainsi que les choix d'implémentation qui en permettent la résolution en temps industriel.

1.5.1 Formulation du problème de calibration

L'objectif est d'ajuster le vecteur de paramètres

$$\Theta = \Big(\rho,\, H,\, \varepsilon,\, \alpha_0, \alpha_1, \alpha_3, \alpha_5\Big)$$

ainsi que, le cas échéant, les nœuds de la courbe de variance forward $\xi_0(\cdot)$, de façon à minimiser simultanément l'écart entre les volatilités implicites du modèle et celles observées sur les marchés du SPX et du VIX, tout en calibrant les prix des futures VIX.

Pour une option call européenne de strike K et de maturité T sur le VIX ou le

SPX, le prix de marché est lié à la volatilité implicite $\sigma(K,T)$ par la formule de Black-Scholes [1] :

$$C_0(K,T) \;=\; F(T)\,\mathcal{N}(d_1) \;-\; K\,\mathcal{N}(d_2), \tag{1.5.1}$$

$$d_1 = \frac{\ln\Big(F(T)/K\Big) + \frac{1}{2}\,\sigma(K,T)^2\,T}{\sigma(K,T)\sqrt{T}}, \qquad d_2 = d_1 - \sigma(K,T)\sqrt{T},$$

$\mathcal{N}$: la fonction de répartition de la loi normale standard.
$F(T) = \mathbb{E}[S_T]$ (respectivement $\mathbb{E}[\mathrm{VIX}_T]$) : le prix forward.

La calibration minimise alors la fonction de coût pondérée suivante :

$$\min_{\Theta} \left\{ c_1 \sqrt{\sum_{i,j} \Big(\sigma^{\Theta}_{\mathrm{spx}}(T_i,K_j) - \sigma^{\mathrm{mkt}}_{\mathrm{spx}}(T_i,K_j)\Big)^2} + c_2 \sqrt{\sum_{i,j} \Big(\sigma^{\Theta}_{\mathrm{vix}}(T_i,K_j) - \sigma^{\mathrm{mkt}}_{\mathrm{vix}}(T_i,K_j)\Big)^2} \right.$$
$$\left. + c_3 \sqrt{\sum_{i} \Big(F^{\Theta}_{\mathrm{vix}}(T_i) - F^{\mathrm{mkt}}_{\mathrm{vix}}(T_i)\Big)^2} \right\}$$

où les notations sont les suivantes :

- $\sigma^{\mathrm{mkt}}_{\mathrm{spx}}(T_i,K_j)$, $\sigma^{\mathrm{mkt}}_{\mathrm{vix}}(T_i,K_j)$: volatilités implicites observées sur le marché pour le SPX et le VIX ;
- $F^{\mathrm{mkt}}_{\mathrm{vix}}(T_i)$: prix du future VIX observé ;
- $\sigma^{\Theta}_{\mathrm{spx}}$, $\sigma^{\Theta}_{\mathrm{vix}}$, $F^{\Theta}_{\mathrm{vix}}$: leurs homologues calculés par le modèle pour les paramètres Θ courants ;
- $c_1, c_2, c_3 > 0$: coefficients de pondération permettant d'équilibrer l'importance relative de chaque source d'information.

Les volatilités implicites du modèle $\sigma^{\Theta}_{\mathrm{vix}}$ sont obtenues par l'estimateur par quadrature de Gauss-Hermite décrit en Section 4, tandis que $\sigma^{\Theta}_{\mathrm{spx}}$ est obtenu via l'estimateur Monte Carlo turbocharge de la Section 5. Cette architecture garantit que l'évaluation de la fonction de coût (1.5.1) reste numériquement tractable lors des itérations d'optimisation.

1.5.2 Extraction de la courbe de variance forward ξ_0

La courbe de variance forward $\xi_0(t)$ joue un rôle structurant dans le modèle : elle assure la cohérence avec les prix de marché des options SPX sur l'ensemble des maturités. Son extraction repose sur la réplication du log-contrat. En notant

$C_0(K,T)$ et $P_0(K,T)$ les prix des calls et puts OTM de strike K et maturité T, on a [1] :

$$\begin{aligned}\int_{T_i}^{T_{i+1}} \xi_0(s)\,\mathrm{d}s = 2&\left[\int_0^{S_0} \frac{P_0(K,T_{i+1})}{K^2}\,\mathrm{d}K + \int_{S_0}^{+\infty} \frac{C_0(K,T_{i+1})}{K^2}\,\mathrm{d}K\right] \\ &- 2\left[\int_0^{S_0} \frac{P_0(K,T_i)}{K^2}\,\mathrm{d}K + \int_{S_0}^{+\infty} \frac{C_0(K,T_i)}{K^2}\,\mathrm{d}K\right]\end{aligned} \tag{1.5.2}$$

Lorsque les prix d'options hors-de-la-monnaie ne sont pas directement observables pour tous les strikes, une interpolation sans arbitrage de la surface de volatilité (par exemple via les paramétrisations SVI ou SABR) est effectuée tranche par tranche afin de permettre le calcul numérique de ces intégrales.

À partir des quantités $x_i = \sqrt{\int_{T_i}^{T_{i+1}} \xi_0(s)\,\mathrm{d}s}$ ainsi obtenues, la fonction ξ_0 est ensuite reconstruite par interpolation par spline cubique sur les nœuds $t_i = (T_i + T_{i+1})/2$, ce qui garantit sa positivité et sa continuité. Lors de la calibration, les valeurs nodales x_i peuvent être optimisées conjointement avec les paramètres Θ, offrant ainsi une flexibilité maximale.

1.5.3 Forme paramétrique de ξ_0

En alternative à l'extraction non-paramétrique ci-dessus, il est possible d'adopter une forme analytique pour ξ_0, ce qui réduit le nombre de degrés de liberté et accroît la stabilité de la calibration sur un nombre limité de tranches. Une spécification courante est la forme exponentielle décroissante :

$$\xi_0(t) \;=\; a\,e^{-bt} + c\Big(1 - e^{-bt}\Big), \qquad a, b, c > 0,$$

où a capture le niveau de variance à court terme, c le niveau asymptotique à long terme, et b la vitesse de convergence entre les deux. Bien que moins flexible, cette formulation se révèle particulièrement adaptée lorsque l'on ne dispose que de quelques tranches SPX et VIX, et elle confère une robustesse appréciable à l'algorithme d'optimisation.

1.5.4 Extension : paramétrisation temporelle de H

Pour les maturités longues (typiquement supérieures à trois ou quatre mois), le paramètre H constant peut s'avérer insuffisant pour reproduire fidèlement la structure par terme du skew. Il est alors avantageux d'introduire une dépendance temporelle :

$$H(t) \;=\; H_0\,e^{-\kappa t} + H_\infty\Big(1 - e^{-\kappa t}\Big), \qquad H_0, H_\infty \in (-\infty, \tfrac{1}{2}),\ \kappa > 0. \tag{1.5.3}$$

Cette interpolation exponentielle entre un régime court terme H_0 et un régime long terme H_∞ conserve la nature gaussienne du processus X (de type Ornstein-Uhlenbeck), ce qui préserve la propriété de simulation exacte établie en Section 5.1. En couplant cette paramétrisation à une courbe ξ_0 ajustable et à une vitesse de réversion ε libre, il devient possible de calibrer simultanément jusqu'à huit tranches SPX et six tranches VIX, y compris sur des horizons supérieurs à un an.

Chapitre 2

Mise en oeuvre algorithmique

Cette partie présente la mise en œuvre algorithmique du modèle quintic Ornstein-Uhlenbeck (OU) pour la calibration jointe des surfaces de volatilité SPX et VIX, suivant la méthodologie d'Abi Jaber, Illand & Li (2023). Elle s'inscrit dans le cadre du rapport collectif et couvre l'intégralité du pipeline de code : des primitives mathématiques jusqu'à l'analyse des résultats de calibration, en passant par le prétraitement des données, le pricing Monte Carlo et la quadrature de Gauss-Legendre.

2.1 Utilitaires mathématiques

Cette première section constitue la fondation technique de l'ensemble du projet. Elle regroupe les primitives de calcul partagées par toutes les sections de pricing et de calibration : formules analytiques de Black-Scholes, inversion numérique de la volatilité implicite, évaluation polynomiale rapide, génération des chemins browniens, densité gaussienne et règle de filtrage du log-moneyness.

2.1.1 Formule de Black-Scholes : `bs_price_call`

Fonctionnement. La fonction `bs_price_call` calcule le prix théorique d'une option d'achat (call) européenne selon le modèle de Black-Scholes. Elle constitue la brique de base sur laquelle reposent toutes les procédures d'inversion et de turbocharging décrites dans ce rapport. Le prix d'un call est donné par

$$C(S, K, T, \sigma) = S\,\mathcal{N}(d_1) - K\,\mathcal{N}(d_2), \tag{2.1.1}$$

où $\mathcal{N}$ désigne la fonction de répartition de la loi normale centrée réduite, et où :

$$d_1 = \frac{\ln\Big(S/K\Big) + \frac{1}{2}\sigma^2 T}{\sigma\sqrt{T}}, \qquad d_2 = d_1 - \sigma\sqrt{T}. \tag{2.1.2}$$

Input. S (spot), K (strike), T (maturité), σ (volatilité).
Output. Prix théorique du call C.

2.1.2 Volatilité implicite par dichotomie : `bs_iv_bisection`

Fonctionnement. Comme il est mathématiquement impossible d'isoler σ analytiquement dans la formule de Black-Scholes, on utilise une méthode numérique de recherche de racine : la *dichotomie* (bisection). L'objectif est de résoudre

$$f(\sigma) = \left| C_{\mathrm{BS}}(S, K, T, \sigma) - \mathrm{Prix}_{\text{marché}} \right| = 0. \tag{2.1.3}$$

L'algorithme procède comme suit :

1. On choisit une borne basse L et une borne haute H encadrant la volatilité cherchée.
2. On calcule le prix au milieu : $m = (L + H)/2$.
3. Si $C_{\mathrm{BS}}(m) > \mathrm{Prix}_{\text{marché}}$, alors la volatilité implicite est inférieure à m : on pose $H \leftarrow m$.
4. Sinon, elle est supérieure : on pose $L \leftarrow m$.
5. On recommence jusqu'à $|H - L| < \varepsilon$.

Input. Prix observé sur le marché, S, K, T, tolérance $\varepsilon = 10^{-8}$.
Output. Volatilité implicite σ^*.

2.1.3 Évaluation polynomiale efficace : `horner_vector`

Fonctionnement. La fonction implémente le schéma de Horner pour évaluer un polynôme de degré n en un nombre minimal d'opérations arithmétiques. Là où une évaluation naïve requiert $\mathcal{O}(n^2)$ multiplications, le schéma de Horner ramène ce coût à $\mathcal{O}(n)$. Elle est utilisée intensivement dans les sections de pricing pour calculer $P(X_t) = \sum_k a_k X_t^k$ sur de grandes grilles.
Input. Coefficients du polynôme $\{a_k\}$, degré n, valeurs x à évaluer.
Output. Vecteur $P(x)$ évalué en chaque point.

2.1.4 Double factorielle : `double_factorial`

Fonctionnement. Calcule la double factorielle $n!!$, qui intervient dans l'expression analytique des moments d'ordre pair d'une variable gaussienne centrée :

$$\mathbb{E}\left[X^{2n}\right] = \sigma_t^{2n}\,(2n-1)!! \tag{2.1.4}$$

Elle est utilisée dans la procédure de normalisation de la variance du modèle OU (section 3).
Input. Entier n.
Output. Valeur de la double factorielle $n!!$.

2.1.5 Génération des chemins browniens : `def_bm_path`

Fonctionnement. Génère des incréments gaussiens pour simuler le mouvement brownien avec réduction de variance par la méthode *antithétique* : pour chaque trajectoire $\Delta W \sim \mathcal{N}(0,1)$, la trajectoire opposée $-\Delta W$ est également conservée, exploitant la symétrie de la loi normale pour diminuer l'erreur statistique sans coût supplémentaire.

Input. `n_steps` (nombre de pas de temps), `N_sims` (nombre de simulations).

Output. Matrice des incréments browniens de taille (`n_steps`, $2 \cdot$ `N_sims`) sous forme de paires antithétiques ($+\Delta W$, $-\Delta W$).

2.1.6 Densité gaussienne : `gauss_dens`

Fonctionnement. Calcule la valeur de la densité de probabilité d'une loi normale de moyenne μ et d'écart-type σ en un point x :

$$\varphi(x;\, \mu,\, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right). \tag{2.1.5}$$

Elle est utilisée pour pondérer les résultats de l'intégration numérique de Gauss-Legendre dans les sections de pricing.

Input. x (valeur à évaluer), μ (moyenne), σ (écart-type).

Output. Densité de probabilité $\varphi(x; \mu, \sigma)$.

2.1.7 Règle de filtrage du log-moneyness SPX : `spx_lm_range_rule`

Fonctionnement. Définit la plage de log-moneyness $m = \ln(K/S_0)$ admissible selon la maturité. Le smile SPX est très cambré à court terme et s'aplatit pour les longues maturités ; cette règle heuristique adapte la fenêtre de filtrage en conséquence :

- $T < 2$ semaines : on ne garde que les options très proches du prix actuel ($m \in [-0{,}12,\ 0{,}02]$).
- $T > 6$ mois : on accepte des options bien plus éloignées de la monnaie ($m \in [-0{,}70,\ 0{,}15]$).

Input. T_{mat} : maturité de l'option en années.

Output. Liste [borne_basse, borne_haute], utilisée dans `preprocess_spx` slice par slice.

2.2 Prétraitement et variance forward

Cette section assure le chargement, le nettoyage et la structuration des données de marché relatives aux options SPX et VIX. Elle produit en sortie les objets nécessaires à la calibration : données filtrées, tranches de maturité et courbe de variance forward.

2.2.1 Nettoyage des options SPX : `preprocess_spx`

But. Nettoyer le carnet d'ordres SPX, S0 étant donné, et ne garder que les options OTM car ce sont elles qui contiennent l'information la plus pertinente sur la volatilité.

Fonctionnement.

1. **Filtrage OTM.** On force la sélection des puts pour $K < S_0$ et des calls pour $K \geq S_0$.
2. **Seuil de liquidité.** Supprimer les options dont le prix bid est inférieur à 0,50.
3. **Application de la règle de maturité.** Appliquer `spx_lm_range_rule` pour filtrer les options hors de la plage de log-moneyness admissible selon la maturité.
4. **Calcul du spread IV.** Estimer l'écart entre le prix du bid et de l'ask en termes de volatilités implicites `bid_iv` et `ask_iv`.

Input. DataFrame `spx_raw` brut issu du CSV.
Output. DataFrame `spx_clean` filtré, prix spot S_0.

2.2.2 Estimation des forwards VIX : `estimate_vix_forwards`

But. Calculer le prix forward du VIX à chaque échéance, car le champ `vix_future_price` du CSV contient le VIX spot pour toutes les maturités et est donc inutilisable directement pour la calibration.

Fonctionnement. Utiliser la parité put-call sur les options VIX. Pour un strike K disposant d'un call et d'un put cotés, le forward implicite vérifie :

$$F_T = K + C(K,T) - P(K,T). \tag{2.2.1}$$

On calcule cette relation pour tous les strikes near-ATM communs et on en prend la moyenne pondérée, les poids étant plus élevés pour les strikes proches du VIX spot afin de minimiser l'impact des erreurs de cotation sur les wings.

Input. DataFrame `vix_raw` brut.
Output. Dictionnaire $\{$*échéance* : *prix_forward*$\}$ (`vix_forwards`).

2.2.3 Filtrage des données VIX : `preprocess_vix`

Fonctionnement. Filtre final qui prépare les données d'options sur le VIX avant leur injection dans l'algorithme de calibration. Il opère en trois étapes :

1. Remplacer `vix_future_price` par les valeurs calculées via `estimate_vix_forwards`, assurant la cohérence interne des prix forward.
2. Sélectionner les OTM calls en ne conservant que les options dont le strike vérifie $K > F_t$: ce sont elles qui portent l'information sur la queue ascendante du VIX.
3. Appliquer un filtrage de sécurité $F < K < 2{,}5\,F$ pour écarter les options sans valeur significative.

Input. Dictionnaire `vix_forwards`, DataFrame `vix_raw`.
Output. DataFrame VIX filtré.

2.2.4 Sélection des tranches de maturité : `select_slices`

Fonctionnement. Sélectionne intelligemment les tranches de maturité bien espacées dans le temps pour la calibration. La fonction procède en trois étapes :

1. Chercher les maturités communes ou proches entre les données SPX et VIX.
2. Éliminer les options expirant dans moins de 7 jours, trop instables numériquement.
3. Sélectionner 3 tranches pour le SPX et 2 pour le VIX, réparties uniformément dans le temps.

Input. DataFrames SPX et VIX, nombre de tranches souhaitées.
Output. Listes des maturités sélectionnées et dictionnaires des données correspondantes.

2.2.5 Extraction de la variance forward : `extract_forward_variance`

Fonctionnement. Calcule la courbe de variance forward $\xi_0(T)$ à partir des prix d'options de marché en deux étapes.

Input. DataFrame `spx` filtré, prix spot S_0, nombre de nœuds `n_nodes` (défaut : 8).

Étape 1 : intégration par réplication. On calcule la variance cumulée jusqu'à la maturité T via la formule de réplication :

$$W(T) = 2\left(\int_0^{S_0} \frac{P(K,T)}{K^2}\,dK + \int_{S_0}^{\infty} \frac{C(K,T)}{K^2}\,dK\right). \tag{2.2.2}$$

Les prix n'étant disponibles qu'en un nombre fini de strikes, cette intégrale est calculée numériquement par la méthode des trapèzes.

Étape 2 : passage à la variance forward. La variance forward instantanée est obtenue en différenciant $W(T)$ par rapport au temps. Entre deux maturités successives T_i et T_{i+1} :

$$\xi_0(T) = \frac{d}{dT} W(T) \approx \frac{W(T_{i+1}) - W(T_i)}{T_{i+1} - T_i}. \tag{2.2.3}$$

Output. Courbe $\xi_0(T)$ constituant l'entrée fondamentale des sections de pricing.

2.3 Pricing SPX : Monte Carlo et turbocharging

Cette section implémente le moteur de pricing des options SPX par simulation Monte Carlo dans le cadre du modèle de volatilité rugueuse. Deux variantes sont proposées : `mc_spx_spline`, qui interpole la courbe de variance forward via une spline cubique appliquée sur $\sqrt{\xi_0}$, et `mc_spx_parametric`, qui utilise la formule analytique $\xi_0(t) = a\, e^{-bt} + c\,(1 - e^{-bt})$. L'algorithme est identique pour les deux variantes principales ; seule la source de ξ_0 diffère.

— **Input :** Paramètres (ρ, H, ξ, α_i), courbe ξ_0, chemins browniens.

— **Output :** Prix des calls et volatilités implicites associées.

— **Fonctionnement :**

1. Simulation du processus X_t par intégration fractionnaire discrétisée.
2. Construction de la variance V_t via le polynôme quintic.
3. Application du terme de normalisation analytique $\mathbb{E}[P(X_t)^2]$ calculé à partir des moments gaussiens (*référence Chapitre 1, Section 1.2.2*).
4. Réduction de variance par *Turbocharging* : calcul du prix conditionnel Black-Scholes corrigé par la variable de contrôle de la variance réalisée puis pour chaque trajectoire simulée du brownien W, nous calculons également le prix pour la trajectoire W. L'estimateur est la moyenne des deux, ce qui élimine les termes d'ordre impair dans l'erreur de simulation.

2.3.1 Extension à un Hurst variable : `mc_spx_timedepth`

Fonctionnement. Cette variante traite le cas où l'exposant de Hurst dépend du temps selon une dynamique de retour à la moyenne :

$$H(t) = H_0\, e^{-H_{\mathrm{mr}}\, t} + H_\infty \Big(1 - e^{-H_{\mathrm{mr}}\, t}\Big). \tag{2.3.1}$$

Lorsque H varie, la variance de X_t n'admet plus de forme analytique fermée. On utilise alors les nœuds de Gauss-Legendre pour intégrer numériquement :

$$\mathrm{Var}(X_t) = \int_0^t \eta(s)^2 \exp\Big(-2\int_s^t \kappa(u)\,du\Big)\,ds. \tag{2.3.2}$$

Input. H_0, H_∞, H_{mr} (mean reversion de Hurst).
Output. Prix des options et volatilités implicites.

Les fonctions support mobilisées par l'ensemble des variantes sont :

— `horner_vector` : évaluation rapide de $P(X_t)$.

— `bs_price_call` : prix conditionnel BS pour le turbocharging.

— `vec_find_vol_rat` : inversion de BS pour obtenir l'IV finale.

2.4 Pricing VIX : quadrature de Gauss-Legendre

Cette section calcule le prix du Future VIX et des options VIX par une méthode de quadrature semi-analytique. Deux variantes sont proposées : `vix_spline` (variance forward issue de la spline de marché) et `vix_parametric` (formule paramétrique). La variante `vix_timedepth` étend le calcul au cas d'un Hurst variable $H(t)$.

2.4.1 Algorithme de pricing

Fonctionnement. Le calcul s'articule en quatre étapes :

1. **Préparation de la grille.** Construction de la grille de Gauss-Legendre composée des nœuds x_{gl} et des poids w_{gl}.
2. **Normalisation de la variance.** Calcul de $\mathbb{E}[P(X_T)^2]$ pour normaliser la variance simulée de façon cohérente avec le marché.
3. **Projection polynomiale.** On exploite les moments conditionnels gaussiens pour exprimer $\mathbb{E}[X_s^k \mid X_T]$ sous forme d'un polynôme en X_T :

$$\mathbb{E}\Big[X_s^k \,\Big|\, X_T\Big] = \sum_{i=0}^{k} \binom{k}{i} X_T^i \left(e^{-\kappa(s-T)}\right)^i \mathbb{E}\Big[\xi^{k-i}\Big]. \tag{2.4.1}$$

Cela permet de transformer l'intégrale de variance future en un polynôme en X_T, rendant le calcul entièrement analytique conditionnellement aux nœuds de la grille. Pour chaque nœud y de la grille, on évalue ensuite :

$$\mathrm{VIX}_T(y) = \sqrt{\frac{1}{\Delta}\sum_i \beta_i\,(X_T)^i}. \tag{2.4.2}$$

4. **Intégration finale.** Le prix du Future VIX est obtenu en intégrant VIX_T contre la densité gaussienne :

$$F_T = \int \mathrm{VIX}_T(y)\ \varphi(y)\ dy, \tag{2.4.3}$$

évaluée numériquement par la quadrature de Gauss-Legendre avec les poids w_{gl}.

Input. Paramètres (ρ, H, ξ, a_K) ; grille de quadrature $(x_{\mathrm{gl}}, w_{\mathrm{gl}})$; courbe de variance forward du marché $(\mathrm{fv_nodes}, T_{\mathrm{nodes}})$.

Output. Future VIX F_T, prix des options VIX, volatilités implicites.

2.5 Calibration jointe SPX/VIX

Cette section implémente la calibration jointe des paramètres du modèle quintic OU sur les surfaces de volatilité SPX et VIX simultanément, suivant la méthodologie d'Abi Jaber, Illand & Li (2023). Elle repose sur la classe `Calibrator`, qui orchestre les trois phases de calibration en minimisant une fonction objectif combinant les erreurs quadratiques sur les smiles SPX, VIX et les prix forward du VIX.

2.5.1 Fonction objectif et pondération

Fonctionnement. La fonction objectif agrège trois termes d'erreur quadratique moyenne pondérés :

$$\mathcal{L}(\theta) = c_1\,\mathrm{RMSE}_{\mathrm{SPX}} + c_2\,\mathrm{RMSE}_{\mathrm{VIX}} + c_3\,\mathrm{RMSE}_{\mathrm{futures}}, \tag{2.5.1}$$

avec les coefficients du papier $c_1 = 1$, $c_2 = 0{,}1$, $c_3 = 0{,}5$. La pondération faible sur le VIX ($c_2 = 0{,}1$) reflète le fait que les données SPX sont plus denses et plus fiables ; le terme futures ($c_3 = 0{,}5$) pénalise les erreurs sur le prix du Future VIX, qui doit être reproduit correctement pour assurer la cohérence globale du modèle.

2.5.2 Stratégie d'optimisation

Fonctionnement. Chaque phase de calibration suit la même procédure en deux étapes :

1. **Évolution différentielle (DE).** L'algorithme explore l'espace des paramètres de façon globale avec une population de `popsize` individus sur `maxiter` générations. Les paramètres de mutation (0,5; 1,5) et de recombinaison 0,7 assurent un bon équilibre entre exploration et exploitation.

2. **Polissage local.** L'optimum global trouvé par DE est affiné par la méthode de Nelder-Mead, qui converge vers le minimum local le plus proche avec une tolérance de 10^{-7}.

Pour accélérer les évaluations, les chemins browniens et la grille de quadrature sont pré-générés une seule fois et réutilisés à chaque appel de la fonction objectif. Les données sont sous-échantillonnées à 12 strikes par tranche SPX et 10 par tranche VIX, ce qui réduit le coût de chaque évaluation sans perte significative d'information.

2.5.3 Phase 1 : variance forward par spline (`calibrate_spline`)

Fonctionnement. La phase 1 calibre le modèle en fixant $\varepsilon = 1/52$ (une semaine) et en laissant libres les paramètres du polynôme $\alpha = (a_0, a_1, a_3, a_5)$, la corrélation ρ, l'exposant de Hurst H, et les valeurs de ξ_0 aux nœuds de la spline, initialisées à partir de l'extraction par réplication de la section 2. Cette phase est conçue pour des échéances courtes à moyennes (jusqu'à 3–4 mois) avec 3 tranches SPX et 2 tranches VIX.

Input. Nœuds (T_{nodes}, ξ_0^{init}) extraits du marché ; hyperparamètres d'optimisation (`maxiter`, `popsize`).

Output. Paramètres calibrés (α, ρ, H, ε, ξ_0^{cal}) et valeur de la fonction objectif.

2.5.4 Phase 2 : variance forward paramétrique (`calibrate_parametric`)

Fonctionnement. La phase 2 remplace la spline par la formule analytique à trois paramètres $\xi_0(t) = a\,e^{-bt} + c\,(1 - e^{-bt})$, en conservant $\varepsilon = 1/52$ fixé. Le nombre réduit de paramètres libres (9 au total) rend cette phase plus rapide et plus stable. Elle est adaptée pour des calibrations avec une à deux maturités VIX (2 tranches SPX et 1 tranche VIX).

Input. Données SPX et VIX filtrées ; paramètres d'optimisation.

Output. Paramètres calibrés (α, ρ, H, ε, a, b, c) et valeur de la fonction objectif.

2.5.5 Phase 3 : Hurst variable (`calibrate_timedepH`)

Fonctionnement. La phase 3 est la plus générale : elle laisse libre ε et substitue à H constant la dynamique $H(t) = H_0\,e^{-\kappa t} + H_\infty(1 - e^{-\kappa t})$. La grille de quadrature est portée à 400 nœuds Gauss-Legendre pour maintenir la précision malgré la complexité accrue du calcul de $\mathrm{Var}(X_t)$. Cette phase est recommandée pour des horizons longs jusqu'à 18 mois, avec 4 tranches SPX et 3 tranches VIX.

Input. Nœuds de variance forward ; paramètres H_0, H_∞, κ et facteurs d'échelle sur ξ_0.

Output. Paramètres calibrés (α, ρ, H_0, H_∞, κ, ε, ξ_0^{cal}).

2.6 Visualisation des smiles et interprétation des résultats

La comparaison des performances et des paramètres optimaux obtenus lors des différentes étapes de calibration est synthétisée dans le tableau 2.1. Ces résultats permettent d'évaluer l'apport de chaque configuration, notamment l'influence de la structure de la variance forward et de la dynamique du paramètre de Hurst sur l'objectif de minimisation $\mathcal{L}$.

Paramètre	**Phase 1 (spline)**	**Phase 2 (param.)**	**Phase 3 ($H(t)$)**
Objectif $\mathcal{L}$	0,1797	**0,0714**	0,2146
α_0	0,5396	0,4591	0,6330
α_1	0,1344	0,2643	0,5856
α_3	0,0835	0,6948	0,1119
α_5	0,0333	0,0306	0,2704
ρ	$-0,7444$	$-0,8334$	$-0,3403$
H (ou H_0)	0,0228	0,1890	$-0,1154$
H_∞	—	—	$-1,7773$
κ	—	—	19,4430
ϵ	0,0192	0,0192	0,1150
Tranches SPX / VIX	3 / 2	2 / 1	4 / 3

Table 2.1 – Récapitulatif des paramètres calibrés et des scores d'objectif par phase de test.

2.6.1 Variance forward du marché (Carr-Madan)

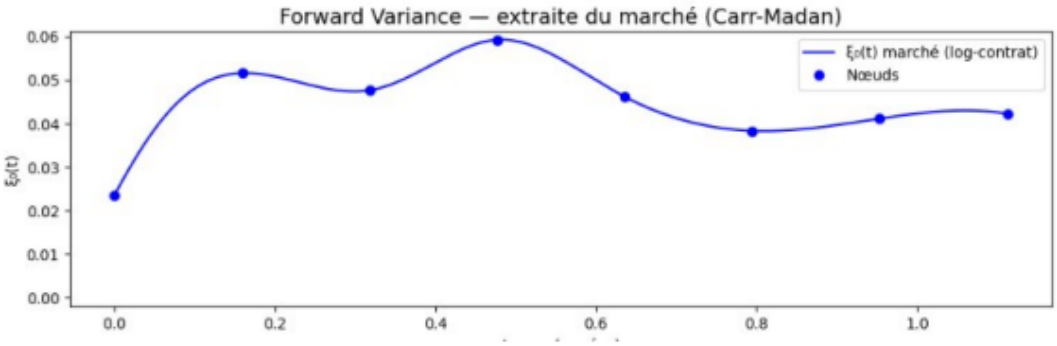

FIGURE 2.1 – Variance forward $\xi_0(t)$ extraite du marché par réplication du log-contrat.

Commentaire. La valeur initiale est basse ($\xi_0(0) \approx 0{,}023$), traduisant un marché calme début avril 2026, avec un pic autour de $t = 0{,}45$ an puis une stabilisation à 0,04. Cette courbe initialise les nœuds de la spline en phase 1.

2.6.2 Phase 2 — ξ_0 paramétrique

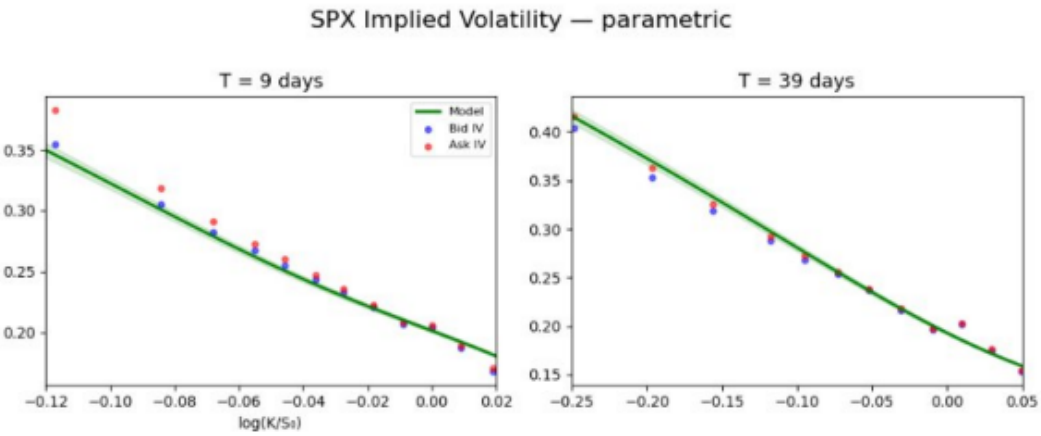

FIGURE 2.2 – Smiles SPX — Phase 2 (T = 9 et 39 jours). Zone verte : IC Monte Carlo à 95 %.

Commentaire. Le fit est excellent sur les deux maturités : la courbe modèle traverse la fourchette bid-ask sur tout le domaine. La forte corrélation négative

($\rho = -0{,}833$) génère le skew observé, et la fonction objectif atteint son minimum ($\mathcal{L} = 0{,}071$).

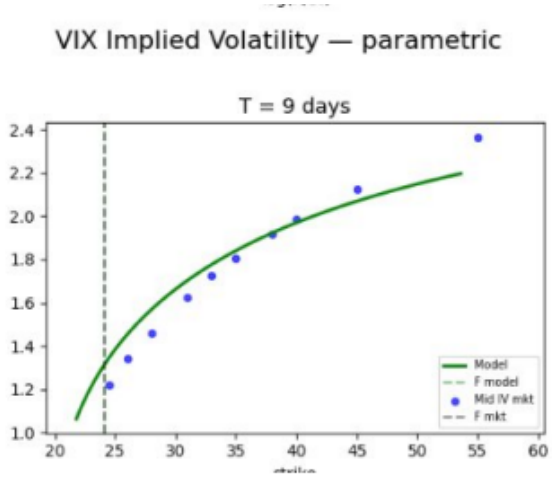

FIGURE 2.3 – Smile VIX — Phase 2 (T = 9 jours).

Commentaire. La courbure ascendante du VIX est bien reproduite. On note une légère sous-estimation aux strikes élevés (> 45), limitation classique des modèles à un facteur.

2.6.3 Phase 1 — ξ_0 spline

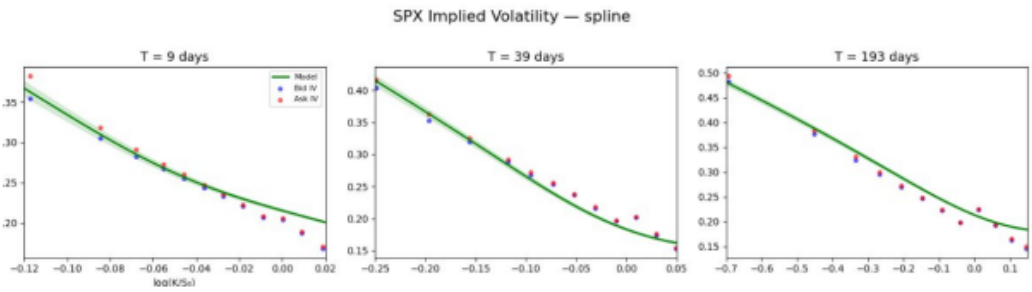

FIGURE 2.4 – Smiles SPX — Phase 1 (T = 9, 39 et 193 jours).

Commentaire. Le fit est très bon à court terme. À 193 jours, un léger écart apparaît sur les wings : le modèle sous-estime les puts profonds et les calls OTM, difficulté inhérente à un H constant sur une large structure par terme.

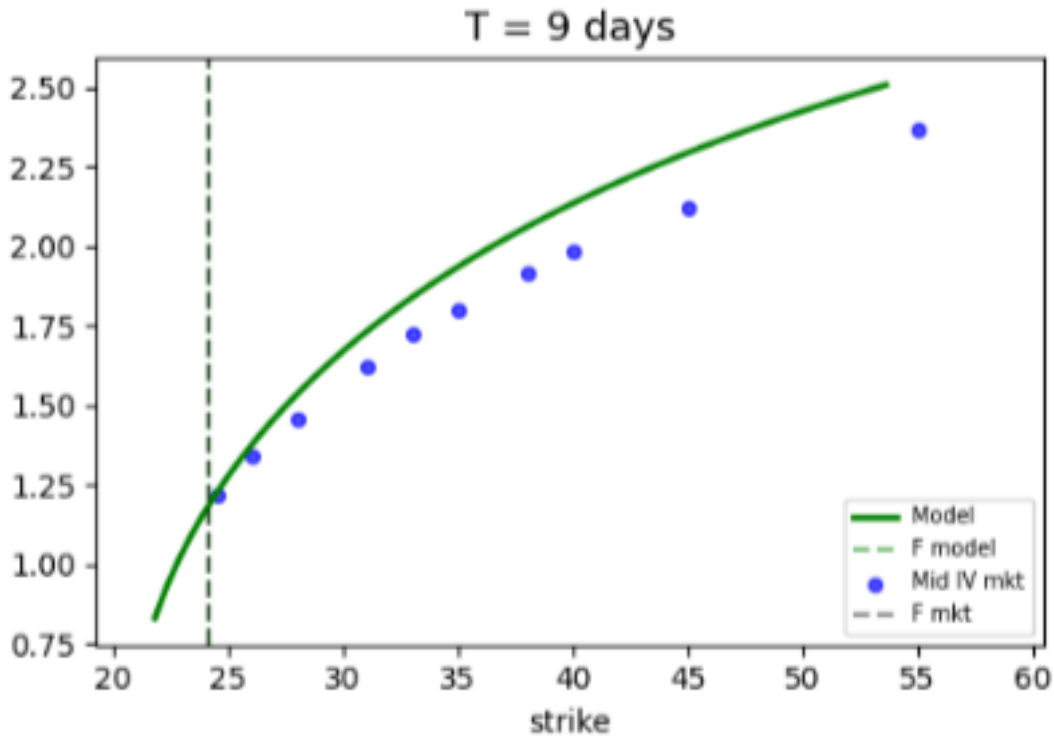

FIGURE 2.5 – Smiles VIX — Phase 1 (T = 9 et 163 jours).

Commentaire. Pour cette maturité à 9 jours, le modèle capture efficacement

la dynamique du VIX. L'utilisation des variables antithétiques et du turbocharging permet d'obtenir une courbe de prix parfaitement lisse et convergée avec moins de volume de simulations. Cette efficacité numérique réduit le bruit statistique, permettant ainsi de constater que, malgré une légère surestimation, la convexité du smile est rigoureusement respectée par le moteur de pricing.

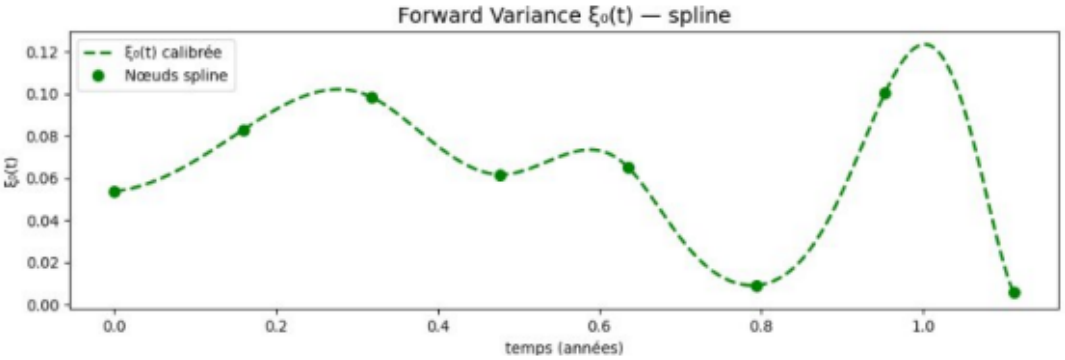

FIGURE 2.6 – Variance forward calibrée $\xi_0(t)$ — Phase 1.

Commentaire. La courbe présente une oscillation plus prononcée que la courbe de marché, avec un pic artificiel à $\xi_0 \approx 0{,}12$ vers $t = 1$ an : artefact classique de la spline cubique non contrainte entre les nœuds.

2.6.4 Phase 3 — $H(t)$ variable

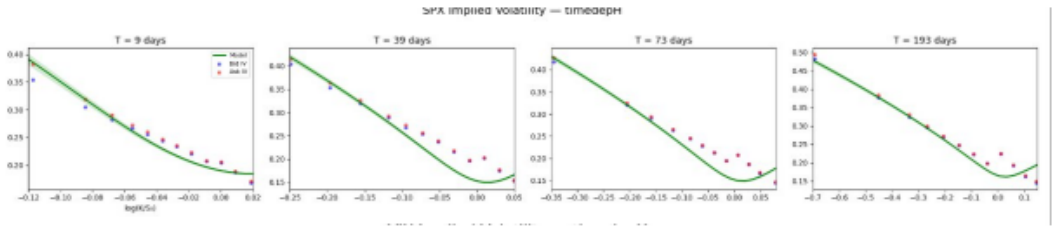

FIGURE 2.7 – Smiles SPX — Phase 3 (T = 9, 39, 73 et 193 jours).

Commentaire. Le modèle reproduit bien la pente du smile sur toutes les maturités. On note un léger défaut sur le wing gauche à 9 jours, tension inhérente à la calibration simultanée sur 7 maturités.

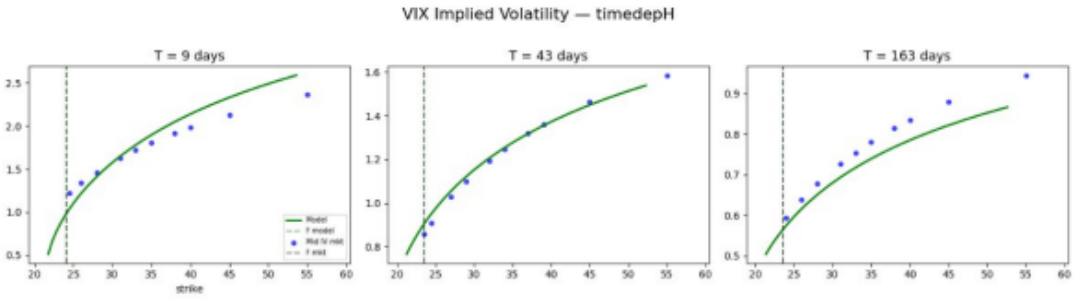

FIGURE 2.8 – Smiles VIX — Phase 3 (T = 9, 43 et 163 jours).

Commentaire. L'amélioration à 163 jours par rapport à la phase 1 est nette : le modèle reste proche du marché sur l'ensemble des strikes. Une légère sous-estimation résiduelle persiste aux strikes élevés à 9 jours.

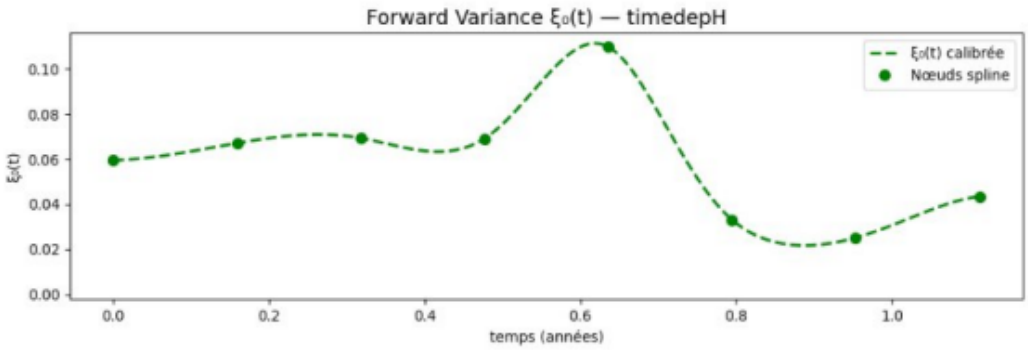

FIGURE 2.9 – Variance forward calibrée $\xi_0(t)$ — Phase 3.

Commentaire. La courbe calibrée est plus régulière qu'en phase 1, avec un pic autour de $t = 0{,}6$ an, plus cohérent avec la structure de terme de marché. La valeur $\varepsilon = 0{,}115$ plus grande lisse naturellement la variance forward.

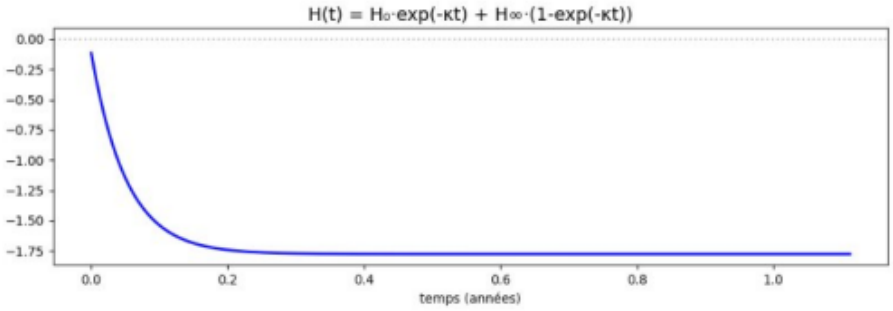

FIGURE 2.10 – Dynamique de Hurst calibrée $H(t)$ — Phase 3.

Commentaire. La convergence est quasi-instantanée ($\kappa = 19{,}44$) de $H_0 = -0{,}115$ vers $H_\infty = -1{,}777$ en moins d'un mois. Une valeur aussi négative encode une anti-persistance forte : retour à la moyenne très rapide de la volatilité à long terme, cohérent avec le comportement empirique du VIX.

2.7 Limites du modèle

2.7.1 Non-convexité de la fonction objectif

La fonction objectif $\mathcal{L}(\theta)$ est hautement non-convexe dans l'espace des paramètres. Le paysage d'optimisation présente de nombreux minima locaux, en raison des interactions entre ρ, H et les coefficients du polynôme α. L'algorithme d'évolution différentielle explore l'espace globalement, mais le polissage local par Nelder-Mead converge vers le minimum local le plus proche, sans garantie de globalité. En pratique, les résultats peuvent varier significativement selon la graine aléatoire ou les bornes de recherche, ce qui rend la calibration sensible à l'initialisation et nécessite des lancements multiples pour valider la robustesse du minimum trouvé.

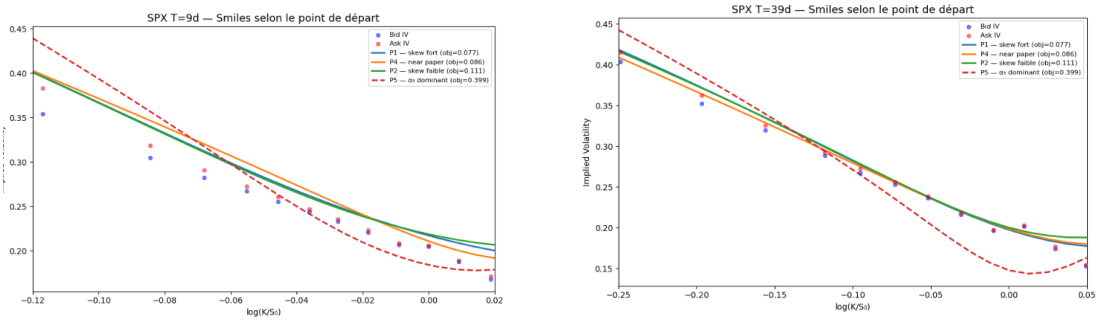

FIGURE 2.11 – Smiles SPX obtenus selon différents points de départ — $T = 9$j (gauche) et $T = 39$j (droite).

Commentaire. Cinq initialisations différentes convergent vers des minima locaux distincts, produisant des smiles significativement différents. P1 et P4 reproduisent bien le marché ($\mathcal{L} \approx 0{,}077$–$0{,}086$), tandis que P5 ($\alpha_5$ dominant) diverge fortement sur les wings ($\mathcal{L} = 0{,}399$). Ce résultat confirme la nécessité d'une exploration globale par `differential_evolution` avant tout polissage local.

2.7.2 Fixation arbitraire des coefficients c_1, c_2, c_3

La fonction objectif combine trois termes d'erreur via des poids fixés *a priori* à $c_1 = 1$, $c_2 = 0{,}1$ et $c_3 = 0{,}5$, repris directement du papier d'Abi Jaber et al.

(2023). Ce choix est arbitraire : rien ne garantit que ces coefficients soient optimaux pour des données différentes de celles utilisées dans le papier, ni qu'ils reflètent correctement l'importance relative des surfaces SPX, VIX et des prix forward dans un contexte de marché donné. En particulier, la faible pondération sur le VIX ($c_2 = 0{,}1$) explique en partie les défauts de fit observés à longue maturité VIX en phase 1 : le calibrateur privilégie systématiquement la surface SPX au détriment de la surface VIX. Une procédure de sélection des poids par validation croisée ou par minimisation d'un critère d'information constituerait une amélioration naturelle .

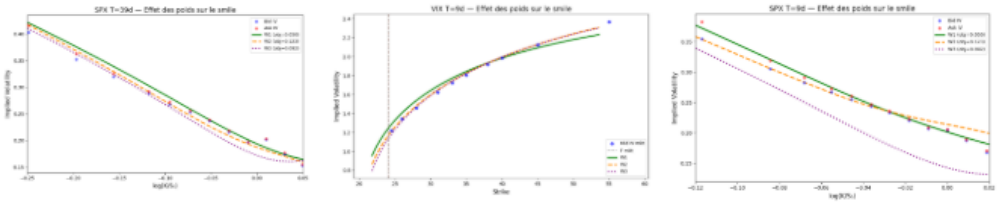

FIGURE 2.12 – Comparaison de la calibration du smile pour différents jeux de poids.

2.7.3 Non-prise en compte des périodes de stress et de crise

Le modèle est calibré sur une coupe transversale de données à une date donnée (6 avril 2026), dans des conditions de marché normales. Il ne modélise pas les régimes de crise : lors d'épisodes de stress (krach éclair, choc macro, crise de liquidité), la surface de volatilité subit des déformations brutales et non linéaires que le modèle quintic OU ne peut pas reproduire. En particulier :

— le skew s'accentue massivement en quelques heures, bien au-delà de ce que ρ peut générer avec une valeur fixe ;

— le VIX peut faire des sauts discontinus (de 20 à 80 en mars 2020), incompatibles avec la continuité du processus X_t ;

— la corrélation entre SPX et VIX se renforce fortement, rendant la calibration jointe instable si les données de stress sont incluses sans repondération.

Une extension naturelle consisterait à introduire un modèle à régimes (Markov-switching) ou à ajouter un processus de saut dans la dynamique de X_t, afin de capturer les comportements extrêmes de la volatilité.

2.8 Synthèse

Le flux de données entre les sections suit une logique linéaire. Les données brutes de marché sont d'abord traitées par la section 2, qui produit la courbe de variance

forward $\xi_0(T)$ et les tranches de maturité sélectionnées. Ces objets alimentent ensuite les sections de pricing : la section 3 calcule les prix des options SPX par simulation Monte Carlo en s'appuyant sur les primitives de la section 1, tandis que la section 4 calcule le prix du Future VIX et des options VIX par intégration de Gauss-Legendre.

$$\underbrace{\text{Données marché}}_{\text{§2 : prétraitement}} \longrightarrow \underbrace{\xi_0(T),\ \text{slices}}_{\text{§3–§4 : pricing}} \longrightarrow \underbrace{\text{Prix SPX/VIX},\ \hat{\sigma}_{\text{imp}}}_{\text{§5 : calibration}}$$

$$\searrow$$

$$\underbrace{\theta^* = (\alpha, \rho, H, \varepsilon)}_{\text{§6 : analyse}}$$

Chapitre 3

Limites et pistes de réflexion

3.1 Motivation et limites du modèle Quintic OU

3.1.1 Rappel du modèle et de sa calibration

Le modèle Quintic Ornstein-Uhlenbeck (Quintic OU), introduit par [**?**], constitue une avancée significative dans la modélisation jointe des surfaces de volatilité implicite du SPX et du VIX. Sa dynamique repose sur un processus de volatilité défini comme une fonction polynomiale de degré cinq d'un unique processus d'Ornstein-Uhlenbeck à retour rapide à la moyenne, ce qui lui confère à la fois une grande flexibilité et une relative parcimonie paramétrique — six paramètres effectifs plus une courbe d'entrée $\xi_0(\cdot)$. La calibration de ce modèle, détaillée dans les sections précédentes de ce rapport, a été conduite en trois phases progressives : une spécification par spline cubique extraite du marché via la formule de réplication de Carr-Madan, une spécification paramétrique de la courbe de variance forward, et enfin une extension à paramètre H dépendant du temps pour couvrir des maturités plus longues. La calibration a été conduite sur les données du 6 avril 2026, avec $\xi_0(t)$ obtenu lors de la Phase 1, correspondant à une spécification par spline cubique extraite du marché.

3.1.2 Limites identifiées : le coût computationnel du Monte Carlo

Malgré ses qualités, le modèle Quintic OU présente une limite opérationnelle importante : le pricing des options SPX repose sur des simulations Monte Carlo (MC). Bien que la simulation du processus OU soit exacte et que la méthode du turbocharging de [7] réduise significativement la variance de l'estimateur, chaque évaluation du prix d'une option nécessite la simulation d'un grand nombre de

trajectoires. Dans notre implémentation, nous utilisons 3 000 chemins lors de la calibration et 4 000 lors de la génération du dataset d'entraînement, avec 200 pas de temps par maturité.

Cette contrainte se traduit concrètement par deux problèmes. D'une part, lors de la calibration, la fonction objectif doit être évaluée des centaines, voire des milliers de fois par l'algorithme d'optimisation, ce qui rend le processus coûteux en temps de calcul, de l'ordre de plusieurs dizaines de minutes à quelques heures selon les paramètres choisis. D'autre part, dans un contexte de gestion des risques ou de recalibration en temps réel, la simulation MC devient un véritable goulot d'étranglement. Un pricer capable de reproduire les sorties du modèle en une fraction de milliseconde, sans perte de précision significative, représenterait donc une amélioration opérationnelle majeure.

C'est précisément dans cette perspective que nous avons envisagé l'introduction d'un réseau de neurones comme outil complémentaire au modèle Quintic OU.

3.2 Les réseaux de neurones pour le pricing : contexte

3.2.1 Différents rôles possibles

L'utilisation des réseaux de neurones en finance quantitative, et plus particulièrement pour le pricing de produits dérivés, a connu un essor considérable ces dernières années. Selon la manière dont ils sont intégrés dans le pipeline de modélisation, les réseaux de neurones peuvent jouer plusieurs rôles distincts qu'il convient de distinguer clairement.

Le premier rôle est celui d'**émulateur** (ou *surrogate model*). Dans cette configuration, le réseau de neurones est entraîné à reproduire la fonction de pricing d'un modèle stochastique donné, à partir de données synthétiques générées par ce même modèle. Une fois entraîné, il se substitue au modèle original lors des évaluations futures, offrant une vitesse d'inférence de plusieurs ordres de grandeur supérieure.

Le deuxième rôle est celui de **calibrateur direct**. L'idée est ici d'entraîner un réseau à inverser la relation paramètres-prix, c'est-à-dire à inférer les paramètres du modèle directement à partir de la surface de volatilité observée. Cette approche est séduisante en théorie, mais se heurte en pratique à des problèmes d'identifiabilité : différents jeux de paramètres peuvent produire des surfaces très similaires, rendant l'inversion difficile à apprendre de manière stable [8].

Un troisième rôle, plus récent, est celui de **modèle de pricing autonome**, où le réseau apprend directement la structure de prix à partir des données de marché, sans s'appuyer sur un modèle stochastique sous-jacent. Cette approche, purement *data-driven*, sacrifie l'interprétabilité théorique au profit de la flexibilité empirique.

3.2.2 Positionnement dans la littérature

L'approche par émulation de modèle a été formalisée et popularisée par [3] dans leur article fondateur *Deep Learning Volatility*. Les auteurs proposent d'entraîner un réseau de neurones profond hors ligne sur un large ensemble de surfaces de volatilité implicite générées par un modèle de volatilité stochastique — en particulier le rough Bergomi — puis d'utiliser ce réseau comme pricer de substitution lors de la calibration. Ils montrent que cette approche réduit le temps de calibration à quelques millisecondes pour la surface complète, tout en conservant une précision comparable à celle du Monte Carlo.

Dans un esprit similaire, [6] démontrent dans *Pricing options and computing implied volatilities using neural networks* qu'un réseau de neurones entraîné sur des données synthétiques issues d'un modèle financier peut apprendre la fonction de pricing avec une très grande fidélité, et ce pour plusieurs modèles de référence (Black-Scholes, Heston). Ces deux travaux constituent le point de départ de notre réflexion et ont directement inspiré l'idée d'adopter une approche similaire dans notre cadre.

3.3 Notre approche : choix et justification

3.3.1 Le réseau de neurones comme émulateur du Monte Carlo

Parmi les différents rôles qu'un réseau de neurones peut jouer, nous avons choisi celui d'émulateur de la simulation Monte Carlo du modèle Quintic OU. Plus précisément, notre réseau apprend la fonction :

$$f : (\alpha_0, \alpha_1, \alpha_3, \alpha_5,\ H,\ \rho,\ \xi_0) \times (T, m) \longmapsto \sigma_{\text{imp}}(T, m) \tag{3.3.1}$$

où $(\alpha_0, \alpha_1, \alpha_3, \alpha_5)$ sont les coefficients du polynôme de volatilité, H est le paramètre de Hurst généralisé, ρ la corrélation entre le SPX et sa volatilité, ξ_0 résume la courbe de variance forward, T la maturité et $m = \log(K/S_0)$ le log-moneyness. La cible est la volatilité implicite SPX correspondante, calculée par Monte Carlo antithétique avec turbocharging. Une fois entraîné, le réseau produit une prédiction en quelques microsecondes, contre plusieurs secondes pour la simulation MC correspondante.

3.3.2 Justification du choix

Fidélité au modèle théorique

Contrairement à une approche purement *data-driven*, l'émulateur apprend à reproduire les sorties d'un modèle théorique bien défini — le Quintic OU — dont les propriétés mathématiques sont connues et rigoureusement établies. Le réseau de neurones est ici un outil numérique, non un modèle financier en soi.

Simplicité de mise en œuvre

Un réseau de neurones entièrement connecté (MLP) standard, entraîné par rétro-propagation sur un dataset synthétique, suffit à obtenir des résultats satisfaisants, comme le montrent [3] et [6].

Compatibilité avec la calibration existante

Le dataset d'entraînement est généré en perturbant les paramètres calibrés autour de leurs valeurs optimales, ce qui garantit que l'émulateur est particulièrement précis dans la région de l'espace des paramètres la plus pertinente pour nos données de marché.

Séparation claire des phases

L'approche retenue maintient une séparation nette entre la phase de calibration — qui reste fondée sur le MC exact — et la phase de pricing rapide assurée par l'émulateur.

3.4 Mise en œuvre

3.4.1 Principe général et pipeline

L'idée centrale de notre implémentation est de construire un approximateur de la fonction de pricing du modèle Quintic OU. Le pipeline complet, implémenté dans un notebook Google Colab en dix cellules séquentielles, s'articule en quatre étapes : la génération hors ligne d'un dataset synthétique (Cellule 5), le prétraitement des données (Cellule 6), l'entraînement du réseau (Cellule 7), et la validation (Cellules 8, 9 et 10).

3.4.2 Génération et description du dataset

Génération du dataset

Le dataset d'entraînement est entièrement synthétique, construit dans la Cellule 5 via la fonction `mc_spx_spline`.

Représentation des paramètres et espace des features. Chaque observation du dataset est caractérisée par 16 variables d'entrée :

$$\mathbf{x} = \Big(\alpha_0, \alpha_1, \alpha_3, \alpha_5,\ H,\ \rho,\ \xi_0^{(0)}, \ldots, \xi_0^{(7)},\ T,\ m\Big) \tag{3.4.1}$$

où $(\alpha_0, \alpha_1, \alpha_3, \alpha_5)$ sont les coefficients du polynôme de volatilité, H le paramètre de Hurst généralisé, ρ la corrélation SPX-volatilité, T la maturité et $m = \log(K/S_0)$ le log-moneyness. La variable cible est la volatilité implicite SPX $\sigma_{\text{imp}}(T, m) \in \mathbb{R}$.

Tirage des paramètres. Les 600 jeux de paramètres sont tirés indépendamment et uniformément dans les plages du Tableau 3.1.

Table 3.1 – Bornes de tirage des paramètres et valeurs calibrées (Phase 1, 6 avril 2026)

Paramètre	Borne inf.	Borne sup.	Valeur calibrée
α_0	0.10	1.50	0.540
α_1	0.01	0.80	0.134
α_3	0.00	0.60	0.084
α_5	0.00	0.20	0.033
H	-0.40	0.30	0.023
ρ	-0.95	-0.50	-0.744
$\xi_0^{(k)}$, $k = 0, \ldots, 7$	0.001	0.15	(voir Tableau 3.2)

Table 3.2 – Nœuds temporels et valeurs calibrées de $\xi_0(t)$ — Phase 1, 6 avril 2026

Nœud	T_k (années)	$\xi_0^{(k)}$ calibré
$\xi_0^{(0)}$	0.000	0.0395
$\xi_0^{(1)}$	0.159	0.0754
$\xi_0^{(2)}$	0.318	0.0707
$\xi_0^{(3)}$	0.477	0.0657
$\xi_0^{(4)}$	0.636	0.0552
$\xi_0^{(5)}$	0.795	0.1026
$\xi_0^{(6)}$	0.953	0.0289
$\xi_0^{(7)}$	1.112	0.1055

Une contrainte supplémentaire $\alpha_0 + \alpha_1 \geq 0.30$ est imposée lors du tirage afin d'assurer un niveau minimal de volatilité et d'éviter des configurations numériquement dégénérées. Les nœuds temporels T_{nodes} sont maintenus fixes pour tous les jeux de paramètres : seules les valeurs nodales $\xi_0^{(k)}$ varient.

Grilles de maturités et de log-moneyness. Pour chaque jeu de paramètres, la volatilité implicite est calculée sur six maturités $T \in \{0.03, 0.05, 0.08, 0.12, 0.17, 0.25\}$ (soit environ 11, 18, 29, 44, 62 et 91 jours) et 19 niveaux de log-moneyness entre -0.35 et $+0.08$, avec une concentration accrue près de la monnaie. Au total : $600 \times 6 \times 19 = 68\,400$ points théoriques.

Simulation Monte Carlo. Les prix sont calculés avec $N = 4\,000$ chemins et $n_{\text{steps}} = 200$ pas de temps, avec variantes antithétiques et turbocharging [7]. Les observations invalides sont écartées, ce qui conduit à **65 740 points valides** (taux de succès : 96.1%).

Description du dataset

Le dataset final contient 65 740 observations valides, chacune représentant un triplet (jeu de paramètres, maturité, log-moneyness) associé à une volatilité implicite SPX calculée par Monte Carlo.

Distribution des volatilités implicites. La Figure 3.1 montre la distribution des volatilités implicites cibles : unimodale, asymétrique à droite, concentrée entre 0.10 et 0.40, avec une queue droite pour les options deep OTM à courte maturité.

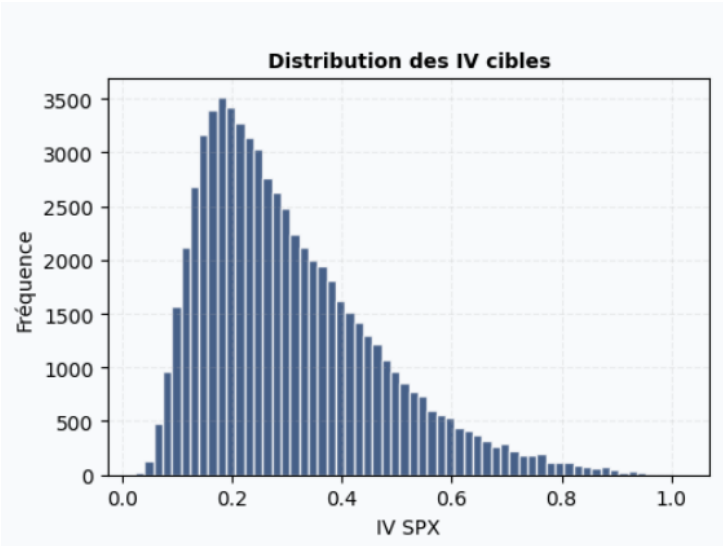

FIGURE 3.1 – Distribution des volatilités implicites cibles σ_{imp} dans le dataset. La distribution est unimodale et asymétrique à droite, concentrée entre 0.10 et 0.40.

Structure du smile. La Figure 3.2 représente les volatilités implicites en fonction du log-moneyness. La pente négative caractérise le skew SPX. La dispersion verticale reflète la diversité des 600 jeux de paramètres, plus importante pour les strikes deep OTM ($m < -0.20$).

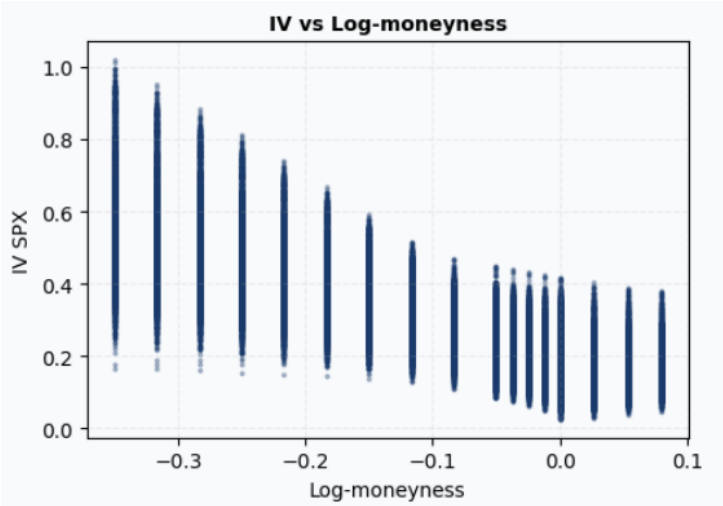

FIGURE 3.2 – Volatilités implicites σ_{imp} en fonction du log-moneyness $m = \log(K/S_0)$. La pente négative caractérise le skew SPX.

Structure par terme. La Figure 3.3 montre que les IV sont plus dispersées pour les courtes maturités (T = 11j et 18j) et convergent vers des valeurs plus homogènes pour les longues maturités, conformément à la structure par terme habituelle du smile SPX.

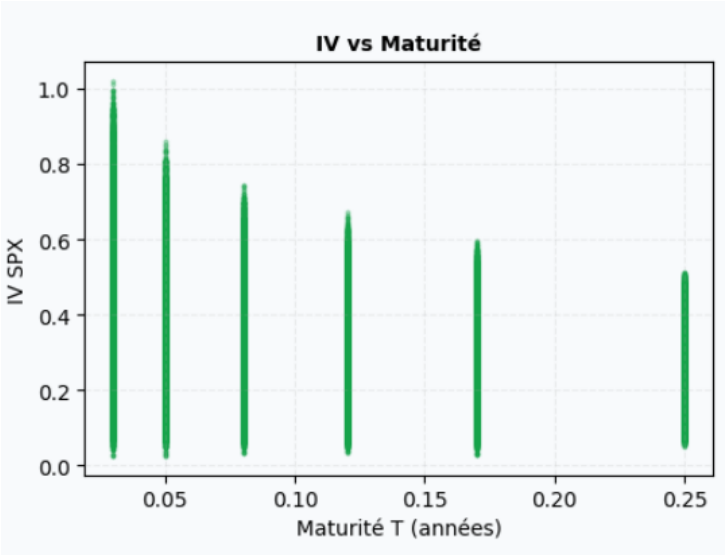

FIGURE 3.3 – Volatilités implicites σ_{imp} en fonction de la maturité T. La dispersion décroît avec la maturité.

3.4.3 Architecture et entraînement

Prétraitement

Le dataset est découpé en un **ensemble d'entraînement** (80%, soit 52 592 observations) et un **ensemble de test** (20%, soit 13 148 observations). Les 16 features sont normalisées par standardisation (`StandardScaler`) : chaque variable est centrée et réduite sur l'ensemble d'entraînement uniquement. La variable cible σ_{imp} n'est pas normalisée.

Architecture du réseau

Le réseau retenu est un **perceptron multicouche entièrement connecté** (MLP) à quatre couches cachées :

$$16 \xrightarrow{\text{couche 1}} 512 \xrightarrow{\text{couche 2}} 256 \xrightarrow{\text{couche 3}} 128 \xrightarrow{\text{couche 4}} 64 \xrightarrow{\text{sortie}} 1 \tag{3.4.2}$$

Dans chaque couche cachée, chaque neurone calcule une combinaison linéaire pondérée de ses entrées puis applique la fonction d'activation ReLU :

$$z = \sum_{i=1}^{n} w_i x_i + b \qquad \text{sortie} = \text{ReLU}(z) = \max(0, z) \tag{3.4.3}$$

La ReLU introduit la non-linéarité indispensable pour capturer la forme complexe du smile de volatilité implicite. La couche de sortie est linéaire. Le nombre total de paramètres apprenables est :

$$\underbrace{16 \times 512 + 512}_{\text{couche 1}} + \underbrace{512 \times 256 + 256}_{\text{couche 2}} + \underbrace{256 \times 128 + 128}_{\text{couche 3}} + \underbrace{128 \times 64 + 64}_{\text{couche 4}} + \underbrace{64 \times 1 + 1}_{\text{sortie}} \approx 281\,025 \tag{3.4.4}$$

Procédure d'entraînement

L'entraînement repose sur une répétition cyclique de quatre opérations :

1 — Propagation avant. À chaque itération, un mini-batch de 512 observations traverse le réseau couche par couche pour produire 512 prédictions $\hat{\sigma}_{\text{imp}}$.

2 — Calcul de l'erreur. On calcule l'erreur quadratique moyenne :

$$\mathcal{L} = \frac{1}{512} \sum_{i=1}^{512} \left(\hat{\sigma}_i - \sigma_i^{\text{MC}} \right)^2 \tag{3.4.5}$$

3 — Rétropropagation. L'erreur est propagée en sens inverse pour calculer le gradient de chaque poids.

4 — Mise à jour des poids. L'algorithme **Adam** [5] ajuste chaque poids en tenant compte de l'historique des gradients. Le taux d'apprentissage initial est 5×10^{-4} et la régularisation L2 est $\lambda = 5 \times 10^{-5}$.

Une époque correspond à $\lfloor 52\,592/512 \rfloor \approx 103$ itérations. Un **arrêt anticipé** interrompt l'entraînement si la perte de validation (10% du train) ne s'améliore plus pendant 30 époques consécutives.

Convergence

La Figure 3.4 montre la courbe de loss : la convergence est atteinte après **340 époques**, avec une loss décroissant de 10^{-3} à 10^{-5} sans divergence entre train et validation.

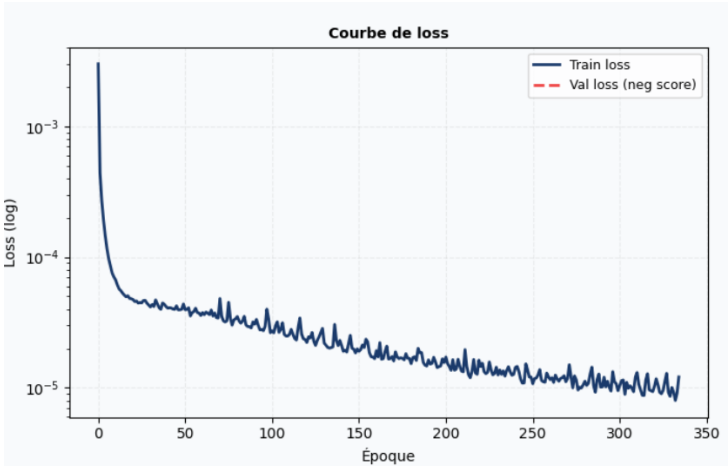

FIGURE 3.4 – Courbe de loss d'entraînement sur une échelle logarithmique. La loss décroît de 10^{-3} à 10^{-5} en 340 époques sans divergence entre train et validation, confirmant l'absence de surapprentissage.

3.5 Résultats

3.5.1 Performance d'émulation : le MLP comme substitut du Monte Carlo

Les métriques obtenues sur le jeu d'entrainement sont présentées dans le Tableau 3.3, et le graphique prédiction vs réel est présenté dans la Figure 3.5.

TABLE 3.3 – Métriques de performance du MLP sur le jeu d'entrainement

Métrique	Valeur
RMSE (vol implicite)	0.00268
MAE (vol implicite)	0.00189
Erreur relative moyenne	0.77%
R^2	0.99972

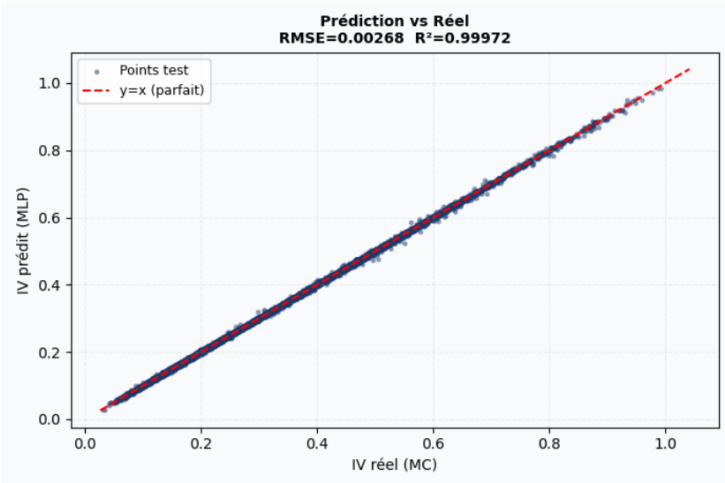

FIGURE 3.5 – Prédiction vs réel sur le jeu d'entrainement. Les points s'alignent quasi parfaitement sur la droite $y = x$, avec RMSE $= 0.00268$ et $R^2 = 0.99972$.

Un R^2 de 0.99972 signifie que le réseau explique 99.97% de la variance des volatilités implicites Monte Carlo. Le RMSE de 0.00268 est inférieur à 0.3 point de volatilité — bien en deçà du bid-ask spread typique des options SPX (1 à 2 points de volatilité), ce qui rend l'erreur d'émulation sans conséquence pratique.

Ce résultat a une portée opérationnelle concrète : le MLP produit une prédiction en quelques microsecondes contre plusieurs secondes pour le Monte Carlo, soit un gain de vitesse de l'ordre d'un million, utilisable pour la recalibration intraday, le calcul des Greeks ou le stress-testing.

3.5.2 Analyse des résidus sur le jeu d'entrainement

L'analyse détaillée des résidus est réalisée dans la Cellule 9. La Figure 3.6 présente simultanément la distribution des erreurs absolues, l'erreur en fonction du log-moneyness et l'erreur par maturité.

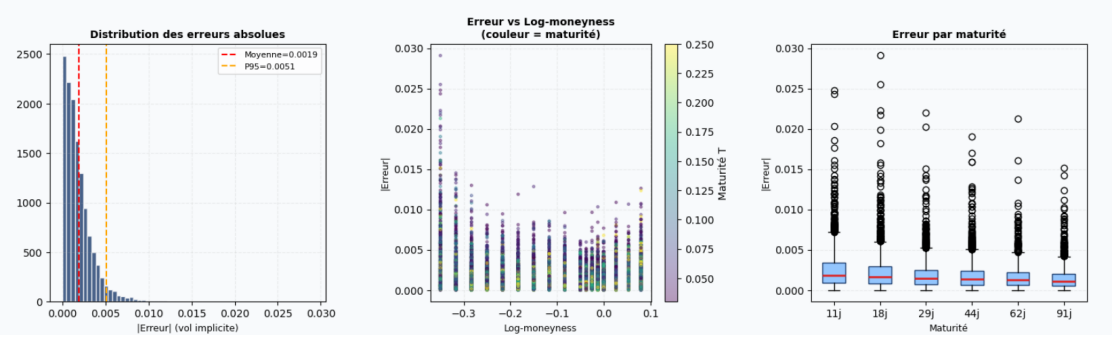

FIGURE 3.6 – Analyse des résidus du MLP sur le jeu d'entrainement. *Gauche* : distribution des erreurs absolues (moyenne = 0.0019, P95 = 0.0051). *Centre* : erreur en fonction du log-moneyness, sans structure systématique. *Droite* : erreur par maturité (boxplot), avec une légère hausse pour T = 11 jours.

La distribution des erreurs absolues est fortement concentrée près de zéro : 99.3% des erreurs sont inférieures à 1 point de volatilité, et 99.9% sont inférieures à 2 points. Le nuage de points erreur vs log-moneyness ne révèle aucune structure systématique — le réseau n'a pas de zone aveugle dans l'espace des strikes. Le boxplot par maturité montre une légère hausse de la dispersion pour T = 11 jours, attendue car le smile est plus courbé sur les horizons courts.

La Figure 3.7 présente l'erreur en fonction de H et de ρ.

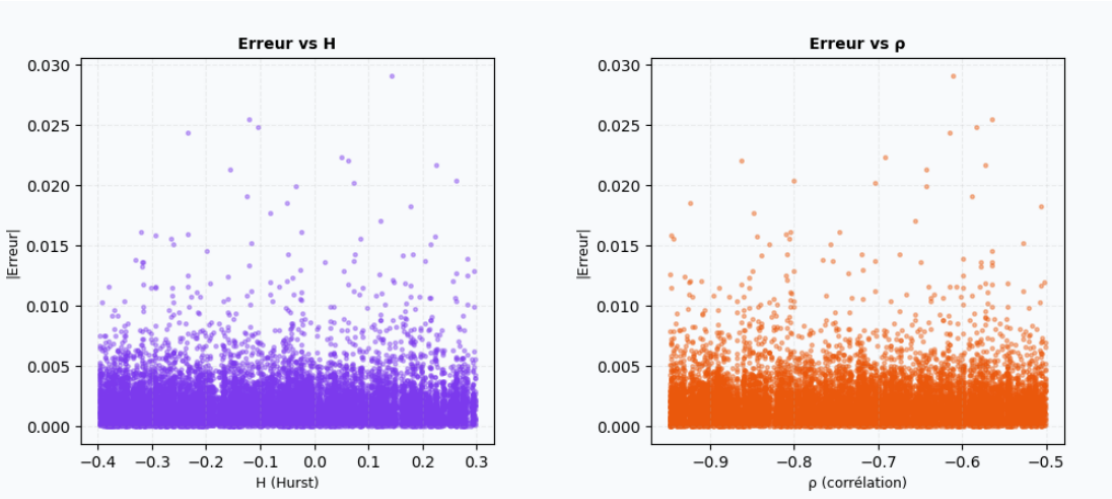

FIGURE 3.7 – Erreur absolue en fonction du paramètre de Hurst H (gauche) et de la corrélation ρ (droite). Aucune dépendance systématique n'est visible, confirmant l'homogénéité de l'apprentissage sur l'espace des paramètres.

Aucune dépendance systématique n'est visible sur les plages $H \in [-0.40, 0.30]$

et $\rho \in [-0.95, -0.50]$, confirmant que le réseau a appris de manière homogène sur l'ensemble de l'espace des paramètres.

3.5.3 Comparaison visuelle avec le marché : smiles SPX

La Figure 3.8 présente la comparaison entre le MLP, le Monte Carlo de référence et les prix de marché du 6 avril 2026 (Cellule 8).

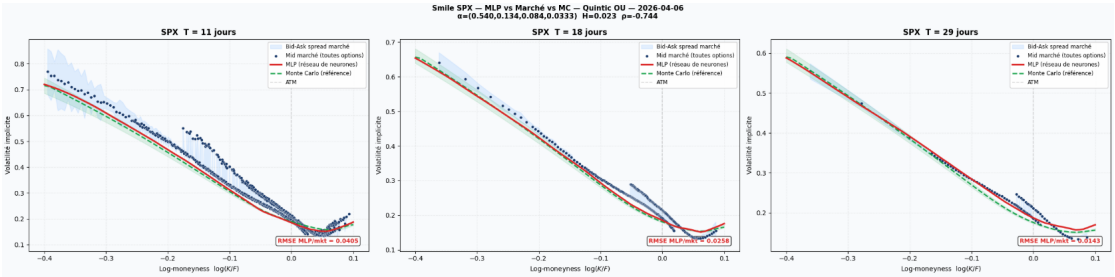

FIGURE 3.8 – Smile SPX — MLP vs Marché vs Monte Carlo — Quintic OU — 6 avril 2026. $\alpha = (0.540, 0.134, 0.084, 0.033)$, $H = 0.023$, $\rho = -0.744$. *Rouge* : prédiction MLP. *Vert pointillé* : Monte Carlo de référence. *Points bleus* : mid IV marché. RMSE MLP/marché : 0.0405, 0.0258 et 0.0143 pour T = 11, 18 et 29 jours.

Sur les trois maturités tracées, la courbe MLP (rouge) et la courbe Monte Carlo (vert pointillé) sont visuellement superposées, validant empiriquement la qualité de l'émulation. Un décalage systématique est visible entre les courbes et les points de marché, en particulier pour T = 11 jours. Cet écart n'est **pas une limitation du MLP** : l'émulateur reproduit fidèlement ce que le modèle prédit. L'écart résiduel est une **limite du modèle Quintic OU lui-même** sur cette journée de sell-off extrême liée à l'annonce de nouveaux tarifs douaniers, pendant laquelle le marché pricait une prime de risque exceptionnellement élevée à très court terme [1].

La décroissance du RMSE MLP/marché avec la maturité ($0.0405 \to 0.0258 \to 0.0143$) s'explique par trois facteurs : les options courtes sont plus sensibles aux effets de microstructure, la panique de marché se concentre sur les très courtes maturités, et la spline $\xi_0(t)$ extrapole pour les maturités inférieures au premier nœud à $T \approx 0.159$ an.

3.5.4 Généralisation sur le jeu de test

La Figure 3.9 présente les smiles produits par le MLP sur des paramètres jamais vus pendant l'entraînement (Cellule 10).

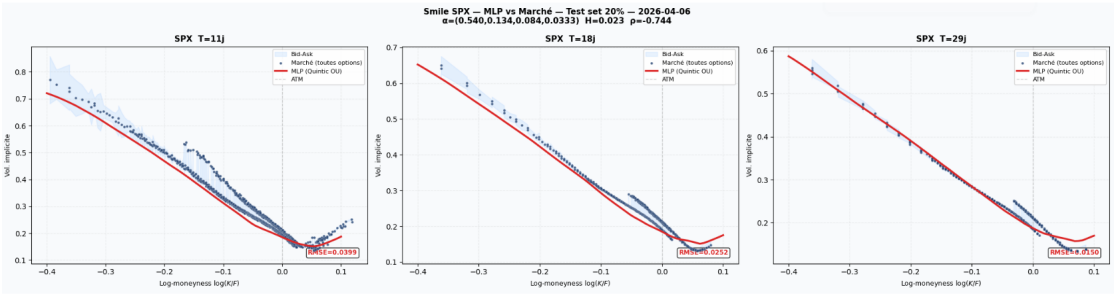

FIGURE 3.9 – Smile SPX — MLP vs Marché — Test set 20% — 6 avril 2026. *Rouge* : prédiction MLP sur paramètres du test set. *Points bleus* : mid IV marché. RMSE : 0.0399, 0.0252 et 0.0150 pour T = 11, 18 et 29 jours.

Les RMSE du test set (0.0399, 0.0252, 0.0150) sont très proches de ceux obtenus avec les paramètres calibrés (0.0405, 0.0258, 0.0143), confirmant une très bonne généralisation. Le réseau n'a pas mémorisé les données d'entraînement mais a appris une approximation générale et stable de la fonction de pricing du modèle.

En synthèse, le MLP constitue un émulateur fidèle et rapide du pricer Monte Carlo du modèle Quintic OU ($R^2 = 0.99972$, RMSE = 0.00268). Les écarts résiduels avec le marché reflètent les limitations intrinsèques du modèle sur une journée de stress extrême, et non une faiblesse de l'émulateur.

Conclusion Générale

Le modèle **Quintic Ornstein-Uhlenbeck (Quintic OU)** s'impose comme une réponse élégante et performante au défi de la calibration conjointe des smiles du SPX et du VIX, couramment appelé le « Joint Calibration Puzzle ». En s'appuyant sur un processus d'Ornstein-Uhlenbeck transformé par un polynôme de degré cinq, il parvient à réconcilier la flexibilité des modèles de volatilité rugueuse — grâce à un retour à la moyenne rapide mimant l'anti-persistance de la volatilité — avec la tractabilité d'un cadre strictement markovien.

L'étude a démontré l'efficacité du modèle pour produire des formules quasi-fermées sur les dérivés du VIX via une quadrature de Gauss-Hermite et des prix SPX précis grâce aux techniques de « turbocharging » par conditionnement de Willard. Cependant, la complexité numérique des simulations de Monte Carlo et la non-convexité de la fonction objectif restent des freins opérationnels. L'intégration d'un réseau de neurones comme émulateur de pricing constitue une avancée majeure, permettant de substituer les simulations coûteuses par un pricer instantané sans perte de fidélité au modèle théorique. En définitive, le modèle Quintic OU, particulièrement lorsqu'il est couplé à l'apprentissage profond, offre un compromis robuste entre précision mathématique et rapidité d'exécution, ouvrant la voie à une gestion des risques plus agile sur les marchés dérivés complexes.

Bibliographie

[1] E. Abi Jaber, C. Illand, and S. Li. The quintic ornstein-uhlenbeck volatility model that jointly calibrates spx & vix smiles. *Quantitative Finance / arXiv*, 2023.

[2] Panagiotis Achtsis, Ronald Cools, and Dirk Nuyens. Conditional sampling for barrier option pricing under the heston model. *arXiv preprint arXiv :1207.6566*, 2012.

[3] C. Bayer, B. Horvath, A. Muguruza, B. Stemper, and M. Tomas. Deep learning volatility : a deep neural network perspective on pricing and calibration in (rough) volatility models. *Quantitative Finance*, 21(1) :11–27, 2019.

[4] J. Guyon. The joint s&p 500/vix smile calibration puzzle solved. *Risk Magazine*, 2022.

[5] D. P. Kingma and J. Ba. Adam : A method for stochastic optimization. *arXiv preprint arXiv :1412.6980*, 2014.

[6] S. Liu, C. W. Oosterlee, and S. M. Bohte. Pricing options and computing implied volatilities using neural networks. *Risks*, 7(1) :16, 2019.

[7] R. McCrickerd and M. S. Pakkanen. Turbocharging monte carlo pricing for the rough bergomi model. *Quantitative Finance*, 18(11) :1877–1886, 2018.

[8] M. Tomas and R. Mehdi. Solving the inverse problem of black-scholes with machine learning. *arXiv preprint arXiv :2010.07079*, 2020.